



Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y
Tecnología

Máster Universitario en Inteligencia Artificial

**Diseño e implementación de un sistema
comparativo de traducción automática
Inga-español mediante fine-tuning de
modelos multilingües y RAG sobre
modelos de lenguaje de frontera**

Trabajo fin de estudio presentado por:	Eslava, Daniel Santos, William
Tipo de trabajo:	Piloto experimental
Director/a:	Víctor David Larco Torres
Fecha:	22 de abril de 2026

Resumen

La lengua Inga, una variante quechua del departamento del Putumayo en Colombia, no dispone de herramientas digitales de traducción. Cerca de 18.000 personas la hablan. Este trabajo aborda esa brecha con un sistema comparativo y bidireccional Inga-español construido sobre dos paradigmas complementarios. El primero adapta el modelo de traducción multilingüe NLLB-200-distilled-600M al par Inga-español mediante adaptadores de bajo rango (LoRA), aprovechando que las lenguas quechuas emparentadas ya están presentes en el preentrenamiento del modelo. El segundo opera sobre el modelo de lenguaje de frontera Claude Sonnet 4.6, enriquecido con recuperación aumentada desde una base de conocimiento estructurada en cuatro índices vectoriales: léxico, gramatical y dos índices de ejemplos paralelos que cubren las dos direcciones de traducción.

El corpus paralelo desarrollado alcanza 5.641 pares verificados, generados mediante alineación canónica entre el Nuevo Testamento en Inga (Wycliffe) y la Reina-Valera 1909 en español, complementados con material jurídico de la Constitución Política de Colombia traducida al Inga por Tandioy Jansasoy y el CCELA de Uniandes. Los pares se distribuyen en particiones de entrenamiento, validación y prueba. La base de conocimiento operativa cubre 4.900 entradas léxicas, 605 bloques gramaticales y 9.024 ejemplos paralelos indexados con embeddings de Gemini sobre LanceDB. La evaluación comparativa de las cinco configuraciones experimentales en ambas direcciones identifica al pipeline LLM con recuperación aumentada como la aproximación con mejor desempeño, alcanzando 17,89 puntos BLEU en la dirección Inga-español y 10,95 en español-Inga sobre el conjunto de validación.

La contribución original del trabajo es tripartita. Primero, una comparación sistemática entre adaptación NMT y recuperación aumentada sobre un mismo par lingüístico de recursos extremadamente bajos. Segundo, un sistema bidireccional que cubre Inga-español y español-Inga con un único adaptador y una arquitectura RAG simétrica. Tercero, la liberación abierta de todos los recursos derivados bajo licencias compatibles con la redistribución a la

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera comunidad Inga, en línea con los principios éticos sistematizados por la literatura reciente sobre MT para lenguas indígenas.

Palabras clave: traducción automática, lenguas indígenas, Inga, transfer learning, recuperación aumentada de información

Abstract

The Inga language, a Quechua variant from the Putumayo region of Colombia, has no available digital translation tools. It is spoken by approximately 18,000 people. This work addresses that gap with a comparative bidirectional Inga-Spanish translation system built on two complementary paradigms. The first adapts the NLLB-200-distilled-600M multilingual translation model to the Inga-Spanish pair using low-rank adapters (LoRA), leveraging the fact that related Quechua languages are already present in the model's pretraining. The second runs on top of the Claude Sonnet 4.6 frontier language model, enriched with retrieval-augmented generation from a knowledge base structured into four vector indices: lexical, grammatical, and two parallel-example indices that cover both translation directions.

The parallel corpus developed in this work reaches 5,641 verified pairs, generated through canonical alignment between the Inga New Testament (Wycliffe) and the Spanish Reina-Valera 1909, complemented with legal material from the Colombian Constitution translated into Inga by Tandioy Jansasoy and the CCELA at Universidad de los Andes. The pairs are distributed into training, validation, and test partitions. The operational knowledge base contains 4,900 lexical entries, 605 grammatical chunks, and 9,024 parallel examples indexed with Gemini embeddings on LanceDB. The comparative evaluation of the five experimental configurations across both directions identifies the LLM pipeline with retrieval-augmented generation as the best-performing approach, reaching 17.89 BLEU points in the Inga-Spanish direction and 10.95 in Spanish-Inga on the validation set.

The original contribution of this work is threefold. First, a systematic comparison between NMT adaptation and retrieval-augmented generation on the same extremely low-resource language pair. Second, a bidirectional system that covers both Inga-Spanish and Spanish-Inga with a single adapter and a symmetric RAG architecture. Third, the open release of all derived resources under licenses compatible with redistribution to the Inga community, in line with the ethical principles recently systematized in the literature on MT for indigenous languages.

Keywords: machine translation, indigenous languages, Inga (Quechua), transfer learning, retrieval-augmented generation

Índice de contenidos

Table of Contents

1. INTRODUCCIÓN	12
1.1. MOTIVACIÓN	12
1.2. PLANTEAMIENTO DEL TRABAJO	14
1.3. ESTRUCTURA DEL TRABAJO	16
2. CONTEXTO Y ESTADO DEL ARTE	18
2.1. CONTEXTO DEL PROBLEMA	18
2.1.1. <i>La lengua Inga y su situación en el Putumayo</i>	18
2.1.2. <i>Marco legal-político en Colombia y contexto internacional</i>	20
2.1.3. <i>Traducción automática de bajos recursos: fundamentos</i>	21
2.1.4. <i>Transfer learning y recuperación aumentada: definiciones</i>	22
2.2. ESTADO DEL ARTE.....	24
2.2.1. <i>Procesamiento del lenguaje natural para lenguas indígenas de América Latina</i>	24
2.2.2. <i>Traducción automática de lenguas indígenas colombianas</i>	25
2.2.3. <i>Traducción automática para quechua: el caso cercano al Inga</i>	26
2.2.4. <i>Modelos de lenguaje de frontera para traducción</i>	27
2.2.5. <i>Recuperación aumentada aplicada a traducción</i>	28
2.2.6. <i>Técnicas de ajuste fino eficiente en parámetros</i>	29
2.2.7. <i>Modelos base candidatos: análisis comparativo</i>	30
2.3. CONCLUSIONES DEL CAPÍTULO	32
3. OBJETIVOS CONCRETOS Y METODOLOGÍA DE TRABAJO	34
3.1. OBJETIVO GENERAL	34
3.2. OBJETIVOS ESPECÍFICOS	34
3.3. METODOLOGÍA DEL TRABAJO.....	36
3.3.1. <i>Enfoque metodológico</i>	36
3.3.2. <i>Fases del proyecto</i>	36
3.3.3. <i>Cronograma</i>	38
3.3.4. <i>Infraestructura de cómputo</i>	39
3.3.5. <i>Configuraciones experimentales a evaluar</i>	40
4. DESARROLLO ESPECÍFICO DE LA CONTRIBUCIÓN	41
4.1. CONFIGURACIÓN DEL ENTORNO COMPUTACIONAL	41

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera	
4.2. CONSTRUCCIÓN DEL CORPUS PARALELO.....	42
4.2.1. Reextracción estructurada del Nuevo Testamento en Inga.....	45
4.2.2. Extracción del Nuevo Testamento en español.....	45
4.2.3. Alineación canónica versículo a versículo.....	46
4.2.4. Antihua Pacay como recurso exploratorio	47
4.2.5. Particiones del corpus	48
4.2.6. Material descartado y sus razones	49
4.2.7. Perfil estadístico del corpus	50
4.3. BASE DE CONOCIMIENTO E INDEXACIÓN VECTORIAL.....	52
4.3.1. Validación cualitativa de la recuperación	55
4.4. ADAPTACIÓN DE NLLB-200 MEDIANTE LoRA BIDIRECCIONAL	56
4.4.1. Lectura de la curva de entrenamiento	59
4.5. PIPELINE LLM + RAG CON CLAUDE	61
4.5.1. Diseño de los prompts por dirección	62
4.5.2. Recuperación multi-índice.....	63
4.5.3. Presupuesto de contexto del prompt	63
4.6. EVALUACIÓN COMPARATIVA	64
4.6.1. Protocolo de evaluación y validez de las métricas.....	70
4.6.2. Análisis cualitativo de las traducciones.....	71
4.6.3. Taxonomía de errores	75
4.6.4. Comparación intra-Claude: por qué el modelo mayor aprovecha mejor el contexto	78
4.6.5. Amenazas a la validez de la evaluación	78
4.7. REPOSITORIO DE CÓDIGO Y DATOS.....	80
5. CONCLUSIONES Y TRABAJO FUTURO.....	81
5.1. CONCLUSIONES	81
5.2. DISCUSIÓN	83
5.3. LÍNEAS DE TRABAJO FUTURAS	86
REFERENCIAS BIBLIOGRÁFICAS	88
ANEXO A. CÓDIGO FUENTE Y DATOS ANALIZADOS	93

Índice de figuras

Figura 1	<i>Ubicación del pueblo Inga en el Putumayo</i>	14
Figura 2	<i>Arquitectura general del sistema comparativo de traducción automática Inga-Español</i>	16
Figura 3	<i>Variantes dialectales del Inga: Alto Putumayo y Medio Putumayo</i>	19
Figura 4	<i>Pipeline de construcción del corpus paralelo Inga-Español</i>	37
Figura 5	<i>Pipeline de ajuste fino eficiente del modelo de traducción multilingüe</i>	37
Figura 6	<i>Pipeline de traducción basado en modelo de lenguaje de frontera con recuperación aumentada</i>	38
Figura 7	<i>Cronograma del proyecto, distribuido por fases y fechas</i>	39
Figura 8	<i>Distribución del corpus paralelo Inga-español por libro y partición</i>	48
Figura 9	<i>Arquitectura del sistema RAG implementado</i>	54
Figura 10	<i>Curva de loss del entrenamiento LoRA bidireccional</i>	59
Figura 11	<i>Comparativa de BLEU, chrF++ y BERTScore por configuración y dirección</i>	69

Índice de tablas

Tabla 1	<i>Organización del trabajo en grupo en la redacción de la memoria</i>	10
Tabla 2	<i>Comparativa de modelos multilingües candidatos para la adaptación al par Inga-Español</i>	31
Tabla 3	<i>Infraestructura de cómputo del proyecto</i>	39
Tabla 4	<i>Configuraciones experimentales a evaluar en la Fase 6 del proyecto</i>	40
Tabla 5	<i>Inventario de recursos lingüísticos primarios utilizados en la construcción del corpus</i>	42
Tabla 6	<i>Distribución del corpus paralelo train/val/test por dialecto</i>	49
Tabla 7	<i>Distribución del corpus paralelo por libro (diez primeros) y fuente</i>	51
Tabla 8	<i>Hiperparámetros del entrenamiento LoRA</i>	57
Tabla 9	<i>Métricas BLEU, chrF++ y BERTScore por configuración y dirección sobre 100 ejemplos del val set</i>	65
Tabla 10	<i>Comparación intra-Claude (Sonnet 4.6 frente a Opus 4.7) sobre el mismo conjunto de validación, métricas BLEU</i>	67
Tabla 11	<i>Ejemplos de traducción por configuración y dirección sobre el conjunto de validación</i>	74
Tabla 12	<i>Recuento de errores por tipo y configuración sobre los 100 ejemplos del conjunto de validación</i>	77

Organización del trabajo en grupo

Partes que aborda el TFE

El presente Trabajo Fin de Máster se desarrolla en modalidad grupal por dos estudiantes y aborda dos contribuciones técnicas autocontenidas que, de forma individual, podrían constituir un trabajo de investigación independiente, además de un componente de infraestructura compartida. Esta partición responde al requisito de la Universidad de que cada integrante realice un aporte técnico suficiente para la obtención del título, tal como se establece en la plantilla oficial para trabajos grupales.

La primera contribución, a cargo de **William Santos**, consiste en la adaptación de un modelo de traducción automática multilingüe preentrenado al par lingüístico Inga-Español mediante técnicas de ajuste fino eficiente en parámetros, aprovechando el conocimiento de lenguas quechuas emparentadas que el modelo ya incorpora como base para la transferencia cross-lingual. Este componente incluye además la curación del corpus bidialectal, Alto Putumayo y Medio Putumayo, labor que se nutre del acceso comunitario del integrante a hablantes nativos en Mocoa, así como la validación lingüística de las salidas del sistema.

La segunda contribución, a cargo de **Daniel Eslava**, consiste en el diseño e implementación de un sistema de traducción basado en un modelo de lenguaje de frontera potenciado con recuperación aumentada de información. El sistema utiliza una base de conocimiento lingüístico del Inga estructurada en tres índices independientes, léxico, gramatical y de ejemplos paralelos, que se consultan dinámicamente durante la inferencia. Este componente incluye adicionalmente el diseño del marco de evaluación comparativa entre ambas aproximaciones, así como la orquestación del pipeline completo de inferencia.

La infraestructura compartida entre ambos integrantes comprende la construcción y curación del corpus paralelo, la normalización ortográfica, la validación con hablantes nativos y el análisis de resultados en la fase de evaluación final.

Distribución y estructura de la memoria

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

La estructura de responsabilidades para la redacción de la memoria se detalla en la Tabla 1.

Tabla 1
Organización del trabajo en grupo en la redacción de la memoria

Apartado de la memoria	Responsables
Introducción	William Santos y Daniel Eslava
Contexto y estado del arte	William Santos (NMT y ajuste fino eficiente), Daniel Eslava (LLMs y RAG)
Objetivos y metodología de trabajo	William Santos y Daniel Eslava
Marco normativo	William Santos (aspectos comunitarios), Daniel Eslava (licenciamiento)
Desarrollo, adaptación del modelo multilingüe	William Santos
Desarrollo, pipeline LLM con recuperación aumentada	Daniel Eslava
Desarrollo, corpus e infraestructura experimental	William Santos y Daniel Eslava
Conclusiones	William Santos y Daniel Eslava

Nota. Elaboración propia.

Mecanismos de coordinación empleados

El trabajo remoto entre los dos integrantes, ubicados en Mocoa (Putumayo) y Cali (Valle del Cauca), exige mecanismos de coordinación formales que aseguren la trazabilidad de las decisiones técnicas y la consistencia de los entregables. Para ello se adoptan los siguientes instrumentos.

En primer lugar, se establece un repositorio compartido en la plataforma GitHub para el código fuente, los *notebooks* de experimentación y la documentación del proyecto, con control de versiones distribuido y revisión cruzada de las contribuciones mediante *pull requests* antes de su integración a la rama principal. En segundo lugar, se utiliza GitHub Projects para la gestión de tareas operativas, con tableros que reflejan las siete fases del proyecto descritas en el Capítulo 3. En tercer lugar, se planifican reuniones síncronas semanales por videoconferencia para revisión de avances, toma de decisiones arquitecturales y resolución de bloqueos; cada reunión produce un acta breve que se archiva en el repositorio. En cuarto lugar, se emplea un gestor bibliográfico compartido (Zotero) que mantiene sincronizadas las referencias verificadas del proyecto, con identificadores estables (DOI, arXiv, ACL Anthology) asociados a cada entrada. Finalmente, la memoria se redacta de forma colaborativa con asignación clara de secciones según la distribución mostrada en la Tabla 1 y revisión cruzada completa antes de cada entrega formal.

1. INTRODUCCIÓN

1.1. MOTIVACIÓN

La lengua Inga, perteneciente a la familia lingüística quechua, constituye un sistema cultural vivo sostenido por aproximadamente 18.000 hablantes del pueblo Inga asentado en el departamento del Putumayo, al suroccidente de Colombia. Sus comunidades se distribuyen principalmente entre dos zonas dialectales: el Alto Putumayo, que abarca el Valle de Sibundoy con los corregimientos de San Andrés y los municipios de Santiago y Colón; y el Medio Putumayo, que comprende Mocoa, Condagua, Yunguillo y Puerto Guayuyaco. A pesar de seguir siendo una lengua de uso cotidiano en el hogar y en la vida comunitaria, el Inga atraviesa un proceso sostenido de desplazamiento frente al español, que opera como lengua dominante en los ámbitos educativo, institucional y digital. Este fenómeno no amenaza únicamente a un sistema de comunicación, sino a toda una cosmovisión y un sistema de conocimiento ancestral transmitido oralmente. La UNESCO (2022), en el *World Atlas of Languages*, advierte que las lenguas indígenas del mundo enfrentan un riesgo de desaparición sin precedentes, y por ello la Organización de las Naciones Unidas ha proclamado la Década Internacional de las Lenguas Indígenas 2022-2032.

Frente a esta realidad, la brecha digital adopta hoy la forma de una exclusión tecnológica. Los grandes traductores comerciales, como Google Translate y DeepL, no contemplan la lengua Inga en su catálogo. En mayo de 2022, Google Translate incorporó Quechua sureño a su conjunto de idiomas soportados, pero la variante Inga del Putumayo continúa excluida. Los escasos recursos digitales disponibles se limitan al *Diccionario Inga* del Valle de Sibundoy (Tandioy Jansasoy et al., 1997), a materiales pedagógicos del Instituto Lingüístico de Verano y a los recursos del programa *Inga Rimangapa Samuichi* de Indiana University, todos ellos con difusión restringida y sin integración computacional. La literatura reciente sobre procesamiento del lenguaje natural en lenguas indígenas de América Latina documenta con claridad este rezago sistemático (Tonja et al., 2024); los primeros esfuerzos de traducción automática para lenguas indígenas colombianas, incluida el Inga, aparecen con Prieto et al. (2024), quienes construyen el primer corpus paralelo documentado. Esta ausencia tecnológica

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera profundiza la brecha entre las lenguas hegemónicas y las lenguas indígenas, y niega al Inga un espacio en el ecosistema digital contemporáneo.

Existe, sin embargo, un marco normativo y una ventana de oportunidad tecnológica que habilitan una respuesta viable desde la inteligencia artificial. La Constitución Política de Colombia (Asamblea Nacional Constituyente de Colombia, 1991) reconoce en su Artículo 10 la oficialidad territorial de las lenguas y dialectos de los grupos étnicos del país, y la Ley 1381 de 2010 desarrolla los derechos lingüísticos de estas comunidades, estableciendo principios explícitos de reconocimiento, fomento, protección, uso, preservación y fortalecimiento (Congreso de la República de Colombia, 2010). Los avances recientes en traducción automática multilingüe masiva, en técnicas de transfer learning desde lenguas emparentadas y en modelos de lenguaje de frontera potenciados con recuperación aumentada de información abren la posibilidad de producir herramientas utilizables para lenguas que hasta hace pocos años eran consideradas intratables. Las consideraciones éticas y comunitarias de este tipo de iniciativas se han sistematizado en la literatura reciente (Mager et al., 2023), y existen antecedentes exitosos de trabajos análogos, como la hoja de ruta desarrollada para el cherokee (Zhang et al., 2022). El presente trabajo se propone contribuir a cerrar la brecha digital del Inga situándose en la intersección de este marco normativo y esta oportunidad técnica.

La ubicación geográfica del pueblo Inga en el departamento del Putumayo, con las principales comunidades de ambos dialectos, se muestra en la Figura 1.

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera




Figura 1

Ubicación del pueblo Inga en el Putumayo

Nota. Elaboración propia con base en datos de OpenStreetMap contributors (ODbL).

1.2. PLANTEAMIENTO DEL TRABAJO

El problema técnico que aborda el presente trabajo es la construcción de un sistema de traducción automática Inga-español utilizable para una lengua que, antes de este proyecto, dispone de menos de 5.000 pares paralelos publicados en la literatura académica y de ningún sistema de traducción comercial o académico funcional. Este contexto define una situación de recursos extremadamente bajos que exige estrategias específicas distintas de las aplicadas a pares lingüísticos con abundancia de datos.

La pregunta de investigación que orienta el trabajo se formula en los siguientes términos: *¿cuál aproximación, el fine-tuning de un modelo de traducción multilingüe preentrenado mediante técnicas eficientes en parámetros, o el uso de un modelo de lenguaje de frontera potenciado con recuperación aumentada de información, resulta más efectiva para traducir del Inga al Español y viceversa cuando los datos paralelos disponibles son extremadamente*

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera *escasos*? Esta formulación tiene dos implicaciones metodológicas. La primera es que no se presume a priori la superioridad de una aproximación sobre la otra: ambas representan paradigmas contemporáneos con evidencia favorable en distintos escenarios, y el trabajo contribuye evidencia comparativa directa. La segunda es que se apuesta por mantener la formulación neutra respecto a modelos o versiones específicas, de modo que la pregunta sobreviva a la evolución tecnológica del campo durante el desarrollo del proyecto.

La propuesta general de solución consiste en el desarrollo en paralelo de ambas aproximaciones sobre un corpus bidialectal construido a partir de recursos comunitarios, textos paralelos existentes y corpus de lenguas quechuas emparentadas. La comparación se realiza mediante métricas automáticas estándar (BLEU, chrF++, BERTScore) y mediante validación cualitativa con hablantes nativos del Inga. Los detalles arquitecturales y metodológicos se presentan en el Capítulo 3.

El alcance del presente trabajo se limita a un piloto experimental local, ejecutable sobre hardware personal, y no a un sistema de producción. Se da cobertura explícita a los dos dialectos principales de la lengua, Alto Putumayo y Medio Putumayo, mediante fuentes documentales específicas de cada zona. Se establece como meta mínima la construcción de un corpus de 5.000 pares de oraciones paralelas, con una meta deseable de 10.000 pares al cierre del proyecto. La liberación de los recursos como bienes comunes para la comunidad Inga queda planteada como resultado natural del trabajo y como línea de trabajo ulterior, sin constituir un objetivo central de evaluación.

La arquitectura general del sistema comparativo propuesto se ilustra en la Figura 2, donde se presentan las dos líneas experimentales que convergen en la evaluación comparativa final.

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera
Arquitectura general del sistema comparativo de traducción automática Inga-Español




Figura 2

Arquitectura general del sistema comparativo de traducción automática Inga-Español

Nota. Elaboración propia.

1.3. ESTRUCTURA DEL TRABAJO

El presente documento se organiza en cinco capítulos, más las secciones de referencias bibliográficas y los anexos técnicos. El Capítulo 1 introduce la motivación del proyecto, el planteamiento del problema y la estructura general del trabajo. El Capítulo 2 desarrolla el contexto del problema, incluyendo la situación sociolingüística del Inga, el marco legal colombiano e internacional aplicable y los fundamentos técnicos de la traducción automática de bajos recursos, y presenta una revisión crítica del estado del arte en traducción automática de lenguas indígenas, con énfasis particular en los trabajos recientes sobre Quechua, que constituye el antecedente más cercano al Inga por pertenecer a la misma familia lingüística. El Capítulo 3 expone el objetivo general, los objetivos específicos y la metodología del trabajo, organizada en siete fases y acompañada del cronograma del proyecto y la descripción de la infraestructura computacional empleada. El Capítulo 4 presenta el desarrollo específico de la contribución; aquí se documentan los avances alcanzados al cierre de las primeras fases del

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

proyecto: la configuración del entorno computacional, el inventario y procesamiento de los recursos lingüísticos primarios, el inicio de la construcción del corpus paralelo y el diseño de la base de conocimiento para la aproximación basada en recuperación aumentada. El Capítulo 5 recoge las conclusiones y las líneas de trabajo futuro; su contenido íntegro se presenta en la Entrega Final del trabajo de fin de Master. Finalmente, se incluyen las referencias bibliográficas consultadas, siguiendo la norma APA séptima edición, y un anexo con el enlace al repositorio público de código y datos del proyecto.

2. CONTEXTO Y ESTADO DEL ARTE

2.1. CONTEXTO DEL PROBLEMA

2.1.1. La lengua Inga y su situación en el Putumayo

La lengua Inga es una variante norteña de la familia quechua, específicamente del grupo Quechua II-B según la clasificación de Torero, que se habla en el suroccidente de Colombia. Comparte con las demás lenguas quechuas una serie de rasgos tipológicos definitorios: es una lengua aglutinante, forma sus palabras mediante la concatenación de sufijos a una raíz, presenta orden sintáctico predominante sujeto-objeto-verbo (SOV), posee un sistema vocálico de tres unidades (/i/, /a/, /u/) y marca los casos gramaticales mediante sufijos nominales (Tandioy Jansasoy et al., 1997). El diccionario de referencia del Inga documenta estos rasgos sistemáticamente y registra la presencia de préstamos léxicos del español (marcados como *Esp*), americanismos (*Amer*) y vocablos provenientes de la lengua vecina Kamsá (*Kamtsa*), con la que el Inga ha mantenido contacto intenso en el Valle de Sibundoy.

El pueblo Inga está asentado principalmente en el departamento del Putumayo, en comunidades distribuidas entre dos zonas geográficas y dialectales claramente diferenciadas: el Alto Putumayo, que comprende el Valle de Sibundoy con los asentamientos de San Andrés, Santiago y Colón, y el Medio Putumayo, que incluye Mocoa, Condagua, Yunguillo, Puerto Guayuyaco y la Bota Caucana, con presencia también en el departamento de Nariño (Aponte) y en el Caquetá. El número de hablantes estimado asciende a aproximadamente 18.000 personas, cifra significativa en el contexto colombiano pero extremadamente reducida en comparación con las lenguas mayoritarias del país.

La existencia de dos variantes dialectales claramente documentadas, el Alto Putumayo (AP) y el Medio Putumayo (MP), con subvariantes como Yunguillo (Yun) y Guayuyaco (Gua), tiene implicaciones directas para cualquier sistema de traducción automática que se adopte. El propio *Diccionario Inga* (Tandioy Jansasoy et al., 1997) registra las diferencias léxicas entre dialectos; a modo de ilustración, el verbo "estornudar" aparece como *achijai* en el Alto Putumayo, *achijii* en Yunguillo y *jachii* en Mocoa. Estas variaciones, que afectan tanto al léxico como a la fonología y la morfología, implican que un corpus paralelo construido

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera exclusivamente desde una variante dialectal no representa adecuadamente al conjunto de hablantes. El presente trabajo aborda esta heterogeneidad incorporando fuentes primarias de ambos dialectos.

La situación sociolingüística del Inga se caracteriza por un desplazamiento progresivo frente al español en los ámbitos institucional, educativo y económico, a pesar de mantener vitalidad en el hogar y la vida comunitaria. El panorama del procesamiento del lenguaje natural para lenguas indígenas de América Latina, sistematizado recientemente por Tonja et al. (2024), documenta que lenguas en esta categoría enfrentan un rezago tecnológico marcado que retroalimenta el desplazamiento sociolingüístico: sin presencia digital se pierde utilidad instrumental, y sin utilidad instrumental se acelera el desplazamiento. La UNESCO (2022), en su *World Atlas of Languages*, describe precisamente este círculo como uno de los principales factores de pérdida acelerada de lenguas en el mundo contemporáneo.

La distinción dialectal entre Alto Putumayo y Medio Putumayo, con ejemplos léxicos tomados directamente del *Diccionario Inga* (Tandioy Jansasoy et al., 1997), se sintetiza en la Figura 3.




Figura 3
Variantes dialectales del Inga: Alto Putumayo y Medio Putumayo

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera
Nota. Elaboración propia a partir del Diccionario Inga (Tandioy Jansasoy et al., 1997).

2.1.2. Marco legal-político en Colombia y contexto internacional

En el ámbito nacional, Colombia dispone de un marco normativo robusto para la protección y promoción de las lenguas indígenas. La Constitución Política de Colombia (Asamblea Nacional Constituyente de Colombia, 1991) establece en su Artículo 10 que "el castellano es el idioma oficial de Colombia. Las lenguas y dialectos de los grupos étnicos son también oficiales en sus territorios". Este principio de oficialidad territorial reconoce al Inga como lengua oficial en las comunidades donde se habla, con las implicaciones jurídicas que ello conlleva en materia de educación, acceso a la justicia y relación con la administración pública.

El desarrollo normativo específico de este reconocimiento constitucional se materializa en la Ley 1381 de 2010 (Congreso de la República de Colombia, 2010), por la cual se desarrollan los artículos 7°, 8°, 10 y 70 de la Constitución Política y se establecen normas sobre el reconocimiento, fomento, protección, uso, preservación y fortalecimiento de las lenguas de los grupos étnicos de Colombia y los derechos lingüísticos de sus hablantes. Esta ley consagra principios como la obligatoriedad estatal de proteger las lenguas nativas, el derecho a la educación intercultural bilingüe, la producción de materiales en lenguas nativas y el acceso a servicios públicos en la lengua propia. Sin embargo, la implementación efectiva de estos principios enfrenta limitaciones operativas importantes, entre ellas la ausencia casi total de herramientas digitales para las lenguas indígenas colombianas.

En el ámbito internacional, la Organización de las Naciones Unidas ha proclamado la Década Internacional de las Lenguas Indígenas 2022-2032, iniciativa cuyo seguimiento técnico se canaliza a través del *World Atlas of Languages* de la UNESCO (2022), un atlas interactivo que reemplaza al antiguo *Atlas of Languages in Danger* y que documenta actualmente 8.324 lenguas en el mundo, de las cuales un porcentaje significativo se encuentra en algún grado de vulnerabilidad o peligro de desaparición. Este marco internacional ofrece un respaldo político y simbólico fundamental, aunque los esfuerzos técnicos concretos, como el presente trabajo, dependen principalmente de iniciativas académicas y comunitarias específicas.

La tensión entre un marco normativo amplio y una disponibilidad real de herramientas digitales es precisamente el espacio en el que se inscribe el presente trabajo. El proyecto se

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera propone aportar evidencia técnica sobre la viabilidad de construir sistemas de traducción automática para lenguas indígenas colombianas utilizando las capacidades actuales de la inteligencia artificial, y contribuir de esta manera al cumplimiento práctico de los mandatos establecidos en la Constitución y la Ley 1381 de 2010.

2.1.3. Traducción automática de bajos recursos: fundamentos

La traducción automática (*Machine Translation* o MT) se define como la tarea computacional de convertir automáticamente un texto de una lengua fuente a una lengua destino preservando su contenido semántico y, en la medida de lo posible, sus propiedades estilísticas. En el contexto del procesamiento del lenguaje natural, las lenguas se categorizan habitualmente según la disponibilidad de recursos paralelos y monolingües: las lenguas de altos recursos, como el inglés, el español o el chino mandarín, cuentan con decenas de millones de pares paralelos publicados; las lenguas de recursos medios disponen de cifras en el orden de cientos de miles a millones de pares; y las lenguas de bajos recursos, entre las que se encuentran la mayoría de las lenguas indígenas del continente americano, disponen de menos de 100.000 pares y a menudo de cifras muy inferiores (Tonja et al., 2024). El Inga se ubica en una categoría aún más restrictiva, denominada en la literatura como "recursos extremadamente bajos" o *extremely low-resource*, caracterizada por disponer de menos de 5.000 pares paralelos antes de la ejecución del presente trabajo.

El paradigma dominante para la traducción automática ha evolucionado significativamente en las dos últimas décadas. Los sistemas de traducción automática estadística (SMT), que dominaron el campo hasta mediados de la década de 2010, fueron reemplazados por los sistemas de traducción automática neuronal (NMT) basados inicialmente en redes recurrentes con mecanismo de atención y, posteriormente, en la arquitectura *Transformer*. El salto cualitativo más reciente ha sido el desarrollo de modelos multilingües masivos entrenados sobre cientos de lenguas simultáneamente, con transferencia cross-lingual incorporada desde el preentrenamiento. El modelo NLLB-200 (No Language Left Behind), presentado por el equipo NLLB y Costa-jussà et al. (2022) y documentado posteriormente en *Nature* por el mismo equipo (NLLB Team et al., 2024), soporta traducción directa entre 200 lenguas, incluidas varias lenguas indígenas americanas como el Quechua Ayacucho (quy_Latn), el

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera Guaraní y el Aymara. Esta propiedad habilita estrategias de transferencia desde lenguas quechuas ya incluidas en el modelo hacia el Inga, aún ausente en los datos de entrenamiento.

Los desafíos específicos de la traducción automática de bajos recursos son técnicos y evaluativos. Desde el punto de vista técnico, la escasez de datos paralelos impide el entrenamiento desde cero de modelos competitivos, y exige estrategias como transfer learning desde modelos preentrenados, augmentación sintética de datos (por ejemplo, *back-translation*), y ajuste fino eficiente en parámetros que no requiera entrenar millones de parámetros sobre corpus minúsculos. Desde el punto de vista evaluativo, las métricas automáticas tradicionales como BLEU fueron diseñadas originalmente para pares de alta disponibilidad de datos y tienden a penalizar en exceso las lenguas aglutinantes como el Inga, donde un mismo contenido semántico admite múltiples realizaciones superficiales válidas. Por ello, la literatura reciente (AmericasNLP 2024 y 2025; Ebrahimi et al., 2024; de Gibert et al., 2025) recomienda métricas basadas en caracteres como chrF++ (Popović, 2017) y métricas basadas en embeddings contextuales como BERTScore (Zhang et al., 2020) o COMET (Rei et al., 2022) como complemento indispensable a BLEU.

2.1.4. Transfer learning y recuperación aumentada: definiciones

El transfer learning o aprendizaje por transferencia en traducción automática consiste en reutilizar representaciones lingüísticas aprendidas por un modelo sobre una lengua de alta disponibilidad de datos como punto de partida para adaptarse a una lengua de baja disponibilidad. La forma más directa de transfer learning en NMT es el ajuste fino (*fine-tuning*) completo, que reentrena todos los parámetros del modelo preentrenado sobre el corpus específico de la lengua objetivo; sin embargo, esta aproximación requiere capacidad de cómputo considerable y es vulnerable al olvido catastrófico de las capacidades cross-lingual adquiridas durante el preentrenamiento. Una alternativa que ha ganado tracción desde 2022 es el ajuste fino eficiente en parámetros (*parameter-efficient fine-tuning* o PEFT), que modifica únicamente un subconjunto reducido de parámetros del modelo. La técnica más difundida en esta línea es *Low-Rank Adaptation* (LoRA), propuesta por Hu et al. (2022), que inserta matrices de bajo rango en las capas de atención del *Transformer* y entrena únicamente esos parámetros adicionales, preservando congelados los pesos originales del modelo

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera preentrenado. Variantes más recientes como QLoRA (Dettmers et al., 2023) y DoRA (Liu et al., 2024) amplían las capacidades de LoRA en escenarios de recursos computacionales limitados o de mayor demanda de calidad.

La recuperación aumentada o *Retrieval-Augmented Generation* (RAG) es un paradigma arquitectural introducido originalmente por Lewis et al. (2020) para tareas intensivas en conocimiento, como la respuesta a preguntas de dominio abierto, que combina un generador neuronal con un mecanismo de recuperación de información. Ante una entrada dada, el sistema recupera fragmentos relevantes de una base de conocimiento externa mediante búsqueda por similitud (generalmente, vectorial con embeddings densos), los inyecta en el contexto del modelo generativo y produce la salida condicionada tanto a la entrada original como al material recuperado. La principal ventaja de RAG reside en que permite inyectar conocimiento específico del dominio sin necesidad de reentrenar el modelo, característica particularmente valiosa cuando los datos de entrenamiento son insuficientes para un ajuste fino tradicional.

La aplicación de RAG específicamente al problema de la traducción automática es relativamente reciente. Wang et al. (2024) proponen RAGtrans como el primer *benchmark* explícitamente dirigido a evaluar sistemas de traducción con recuperación aumentada sobre conocimiento no estructurado. En el contexto de lenguas de bajos recursos, Chen et al. (2024) demostraron con el sistema QueEn que la combinación de RAG con un modelo ajustado mediante LoRA permite alcanzar mejoras sustanciales en la traducción Quechua-Inglés, con incrementos documentados de entre 1.5 y 17.6 puntos BLEU según la configuración experimental. El presente trabajo se inscribe en esta línea emergente de investigación, proponiendo una arquitectura RAG multi-índice específicamente diseñada para inyectar conocimiento lingüístico estructurado, léxico, gramatical y de ejemplos paralelos, en modelos de lenguaje de frontera operando sobre el par Inga-Español.

2.2. ESTADO DEL ARTE

2.2.1. Procesamiento del lenguaje natural para lenguas indígenas de América Latina

El panorama general del procesamiento del lenguaje natural aplicado a lenguas indígenas de América Latina fue recientemente sistematizado por Tonja et al. (2024), quienes analizaron los avances y retos en más de treinta lenguas pertenecientes a familias como la quechua, la tupí-guaraní, la náhuatl-uto-azteca, la maya y la aymara. El estudio identificó tres patrones recurrentes: la severa escasez de corpus paralelos publicados, la ausencia de estandarización ortográfica que dificulta el procesamiento automático, y la concentración de la mayoría del esfuerzo investigador en un subconjunto reducido de lenguas (principalmente Quechua, Guaraní y Nahuatl), con cobertura residual para el resto.

El principal foro canalizador de la investigación específica en traducción automática para lenguas indígenas de América es el taller *Workshop on NLP for Indigenous Languages of the Americas* (AmericasNLP), organizado desde 2021 como evento satélite de NAACL. La cuarta edición del taller, celebrada en 2024, organizó una tarea compartida centrada en traducción español a lenguas indígenas cubriendo once pares lingüísticos, cuyos resultados y análisis fueron publicados por Ebrahimi et al. (2024). La quinta edición, correspondiente a 2025, amplió el alcance a la creación de material educativo y al desarrollo de métricas específicas para lenguas indígenas (de Gibert et al., 2025), consolidando un conjunto estandarizado de corpus, líneas base y protocolos de evaluación que constituyen el estado del arte actual en el campo.

Un aspecto transversal a estos trabajos es la discusión sobre las implicaciones éticas y comunitarias del uso de tecnologías de traducción automática aplicadas a lenguas indígenas. Mager et al. (2023) sistematizaron en el marco de ACL las consideraciones éticas específicas de esta línea de investigación, enfatizando la importancia de la participación comunitaria, el consentimiento informado y el retorno de los beneficios a las comunidades hablantes. El presente trabajo asume estos principios como parte integral de su diseño, tal como se detalla en el marco normativo y en la sección de organización del trabajo.

2.2.2. Traducción automática de lenguas indígenas colombianas

El estado del arte específico para lenguas indígenas colombianas es particularmente escaso. La primera contribución académica documentada que incluye explícitamente al Inga entre sus lenguas objetivo corresponde a Prieto et al. (2024) del equipo investigador de la Universidad de los Andes. En dicho trabajo, presentado en el taller AmericasNLP 2024, los autores construyeron el primer corpus paralelo multilingüe para lenguas indígenas colombianas a partir de fuentes como la Biblia, la Constitución Política y materiales pedagógicos, y aplicaron transfer learning desde el modelo NLLB-200 a cuatro pares: Español-Wayuunaiki, Español-Arhuaco, Español-Inga y Español-Kamsá. Los resultados reportados mostraron la viabilidad técnica del enfoque, aunque con valores BLEU modestos consistentes con la severa escasez de datos (BLEU entre 2 y 10 puntos según el par).

El trabajo de Prieto et al. (2024) fue extendido posteriormente por un equipo relacionado: Salazar, Manrique y Pereira Nunes (2025) publicaron en la revista *SN Computer Science* un análisis más amplio de estrategias de traducción automática para las mismas lenguas, incorporando técnicas adicionales como el ajuste fino eficiente en parámetros y la augmentación sintética de datos. Ambos trabajos constituyen los antecedentes académicos directos del presente trabajo y definen la línea base contra la cual se compararán los resultados finales del proyecto.

Un aporte metodológico del presente trabajo respecto a estos antecedentes consiste en la cobertura explícita de las dos variantes dialectales principales del Inga, Alto Putumayo y Medio Putumayo, distinción que ninguno de los trabajos previos aborda explícitamente. Esta cobertura se sustenta en la incorporación de fuentes primarias específicas de cada dialecto: el *Diccionario Inga* (Tandioy Jansasoy et al., 1997) con sus marcadores dialectales, la *Gramática Pedagógica del Inga* de Levinsohn y Mongui centrada principalmente en el Alto Putumayo, y la cartilla *Antihua Pacay Gentecunapa Parlocuna* (Jamioy Yanangona de Peña, 1985) que documenta narrativas del Medio Putumayo. El detalle de estos recursos y de su procesamiento se presenta en el Capítulo 4.

2.2.3. Traducción automática para quechua: el caso cercano al Inga

Dado que el Inga pertenece a la familia lingüística quechua, los avances recientes en traducción automática para variantes del Quechua constituyen el antecedente técnico más directamente transferible al presente proyecto. Esta sección sintetiza los trabajos más relevantes publicados entre 2024 y 2026.

Chen et al. (2024) presentaron **QueEn**, un sistema de traducción Quechua-Inglés que combina recuperación aumentada con ajuste fino mediante LoRA sobre un modelo de lenguaje grande. Los autores reportaron mejoras en BLEU de entre 1.5 y 17.6 puntos respecto a líneas base estándar, según la configuración experimental. Este trabajo constituye el antecedente metodológico más próximo al presente trabajo, dado que combina las dos técnicas centrales, LoRA y RAG, sobre una lengua quechua. La principal diferencia metodológica es que QueEn utiliza una base de conocimiento unificada, mientras que el presente trabajo propone una base multi-índice con separación explícita entre el conocimiento léxico, gramatical y de ejemplos paralelos.

Garcia Gilabert et al. (2024), del Barcelona Supercomputing Center (BSC), presentaron en AmericasNLP 2024 la submisión ganadora para los pares Español-Quechua y Español-Guaraní. Su propuesta consistió en el ajuste fino de NLLB-200 mediante adaptadores LoRA, entrenando únicamente el 14.2% de los parámetros del modelo original. Este resultado constituye evidencia empírica directa de la viabilidad del enfoque adoptado en el presente trabajo de investigación: demuestra que la arquitectura NLLB+LoRA es competitiva en el estado del arte para una lengua quechua con cantidades de datos similares a las disponibles para el Inga, y que es factible ejecutarla con recursos computacionales moderados.

Attieh et al. (2024) presentaron, también en AmericasNLP 2024, la submisión NordicsAlps, que obtuvo el mejor chrF++ promedio en múltiples pares lingüísticos. Su contribución principal fue metodológica: demostraron el impacto positivo de la tokenización a nivel de bytes (*byte-level*) para lenguas aglutinantes, propiedad compartida por todas las lenguas quechuas incluido el Inga. Este hallazgo orienta las decisiones de preprocesamiento del presente proyecto.

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera DeGenaro y Lupicki (2024) exploraron en la misma edición del taller el contraste entre arquitecturas *Transformer* tradicionales y arquitecturas de estado-espacio como Mamba para traducción de lenguas indígenas. Aunque los resultados no superaron al ajuste fino convencional sobre NLLB-200, el estudio aporta información valiosa sobre la viabilidad de arquitecturas alternativas.

Más recientemente, Dhawan et al. (2026) publicaron una investigación sobre mejoras en la traducción automática de lenguas indígenas mediante datos sintéticos y preprocesamiento específico por lengua, con experimentos sobre Guaraní, Quechua y Aymara. Sus hallazgos sobre normalización ortográfica y filtrado de ruido son particularmente aplicables al corpus Inga, que presenta heterogeneidades ortográficas por provenir de fuentes editadas en distintas épocas y bajo distintos acuerdos de alfabeto.

En conjunto, estos trabajos demuestran que el par tecnológico central del presente trabajo, fine-tuning eficiente sobre NLLB-200 más estrategias complementarias de recuperación aumentada, es una aproximación viable y alineada con el estado del arte para lenguas de la familia quechua.

2.2.4. Modelos de lenguaje de frontera para traducción

La emergencia de modelos de lenguaje de frontera (*frontier LLMs*) con capacidades multilingües ha transformado el panorama de la traducción automática desde 2023. A diferencia de los sistemas de traducción neuronal especializados, como NLLB-200, los LLMs abordan la traducción como un caso particular de generación condicionada mediante *prompting* en lenguaje natural, lo que habilita aproximaciones *zero-shot*, *few-shot* y con recuperación aumentada. La literatura reciente ha documentado tanto las fortalezas como las limitaciones de este paradigma para lenguas de bajos recursos.

Hendy et al. (2023) realizaron una de las evaluaciones más comprehensivas iniciales sobre el desempeño de los modelos GPT en traducción automática, comparándolos con sistemas NMT dedicados a través de 18 pares lingüísticos. Sus resultados documentaron una brecha consistente en favor de los sistemas especializados en los escenarios de bajos recursos, aunque también señalaron que esta brecha se estrechaba significativamente conforme

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera avanzaban las versiones de los LLMs. Este patrón ha sido confirmado y extendido por trabajos posteriores: Zhu et al. (2024) publicaron en *Findings of NAACL 2024* un análisis empírico sistemático de la traducción multilingüe con LLMs en el que confirman que la brecha persiste para lenguas extremadamente poco cubiertas en los datos de preentrenamiento, pero se reduce notablemente en presencia de pocos ejemplos en el *prompt*.

Una contribución particularmente relevante para el diseño del presente documento es el trabajo de Enis y Hopkins (2024), que examinó específicamente las capacidades del modelo Claude de Anthropic en traducción de bajos recursos. Los autores documentaron que, entre los LLMs evaluados, Claude exhibió una "eficiencia de recursos" (*resource efficiency*) diferencial: su calidad de traducción degrada menos que la de otros modelos comparables al pasar de lenguas de altos recursos a lenguas de bajos recursos. Este hallazgo motiva la elección de un modelo de lenguaje de frontera con propiedades similares como línea experimental complementaria al ajuste fino de NLLB en el presente trabajo.

La literatura más reciente sobre *in-context learning* (ICL) en lenguas de bajos recursos ha sido sistematizada por Cahyawijaya, Lovenia y Fung (2024), quienes demostraron en NAACL 2024 que los LLMs operan efectivamente como aprendices *few-shot* cuando se les proporcionan ejemplos cuidadosamente seleccionados, y que la selección por similitud semántica supera consistentemente a la selección aleatoria. Este resultado proporciona el fundamento teórico para el diseño del índice de ejemplos del sistema RAG propuesto en el Capítulo 3, que recupera oraciones paralelas Inga-Español similares a la entrada para inyectarlas como ejemplos *few-shot* al modelo de lenguaje.

2.2.5. Recuperación aumentada aplicada a traducción

La aplicación sistemática del paradigma de recuperación aumentada a la tarea específica de traducción automática es una línea de investigación emergente, con literatura concentrada principalmente en el bienio 2024-2025. El trabajo fundacional del paradigma RAG (Lewis et al., 2020) se propuso originalmente para tareas de dominio abierto intensivas en conocimiento factual, y su adaptación a traducción requiere diseños arquitecturales específicos que distintos autores han explorado recientemente.

Wang et al. (2024) presentaron **RAGtrans**, el primer *benchmark* específicamente diseñado para evaluar sistemas de traducción automática con recuperación aumentada sobre conocimiento no estructurado. Los autores demostraron que la incorporación de conocimiento recuperado mejora consistentemente la calidad de traducción en pares multilingües, especialmente en dominios especializados donde el vocabulario técnico está mal representado en los datos de entrenamiento. Este trabajo establece la validez del paradigma RAG-MT como línea de investigación independiente y proporciona un marco evaluativo transferible al presente proyecto.

El trabajo de Chen et al. (2024) QueEn, ya mencionado en la sección 2.2.3, constituye la aplicación más directa de RAG a una lengua quechua: combina recuperación de contexto relevante con ajuste fino mediante LoRA, demostrando mejoras sustanciales sobre líneas base en Quechua-Inglés. La base de conocimiento utilizada en QueEn es principalmente un corpus de oraciones paralelas; el presente trabajo extiende esta idea proponiendo una base multi-índice que separa explícitamente el conocimiento léxico (entradas del diccionario), el conocimiento gramatical (reglas morfosintácticas) y los ejemplos paralelos, lo que permite al sistema consultar cada tipo de conocimiento de manera específica según la naturaleza de la información que requiere para la traducción.

La literatura actualmente disponible sobre RAG-MT multi-índice es escasa; no se han identificado trabajos previos que estructuren la base de conocimiento lingüístico en índices independientes como se propone en el presente trabajo. Esta estructuración constituye, por tanto, una contribución metodológica original del proyecto.

2.2.6. Técnicas de ajuste fino eficiente en parámetros

El campo del ajuste fino eficiente en parámetros (*parameter-efficient fine-tuning* o PEFT) ha experimentado una expansión notable desde 2021. La técnica más influyente y ampliamente adoptada es *Low-Rank Adaptation* (LoRA), propuesta por Hu et al. (2022) y publicada en ICLR 2022. LoRA se fundamenta en la observación empírica de que los cambios en los pesos de un modelo durante el ajuste fino tienen un rango intrínseco bajo, y reemplaza la actualización de matrices densas por la suma de dos matrices de bajo rango que se entrenan conjuntamente. En la práctica, LoRA reduce el número de parámetros entrenables en tres o cuatro órdenes de

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera magnitud respecto al ajuste fino completo, con pérdida mínima de calidad en la tarea final. Esta propiedad hace a LoRA particularmente adecuado para escenarios con restricciones de cómputo.

Dettmers et al. (2023) propusieron **QLoRA** como una extensión de LoRA que introduce cuantización a 4 bits del modelo base preentrenado, manteniendo los adaptadores LoRA en precisión completa. Esta combinación permite el ajuste fino de modelos significativamente mayores en hardware con memoria limitada sin comprometer la calidad final, ampliando el alcance práctico de la técnica. El trabajo fue publicado en NeurIPS 2023 y constituye la referencia estándar para escenarios con restricciones de memoria.

Liu et al. (2024) presentaron **DoRA** (*Weight-Decomposed Low-Rank Adaptation*) como una evolución de LoRA. La propuesta descompone cada matriz de pesos en una componente de magnitud y una componente de dirección, aplicando LoRA únicamente sobre la componente direccional. El trabajo, publicado como *oral* en ICML 2024, demuestra mejoras sistemáticas sobre LoRA a igual número de parámetros entrenables en varios *benchmarks* de lenguaje natural y visión, y es una alternativa natural a evaluar en etapas avanzadas del trabajo de fin de Master.

Un estudio comparativo especialmente relevante para las decisiones metodológicas del presente trabajo es el de Su et al. (2024), que evaluó empíricamente ocho métodos PEFT sobre quince arquitecturas distintas en el escenario específico de traducción automática de bajos recursos (*low-resource language translation*, LRL-NMT). El estudio recomienda un conjunto de combinaciones modelo-método según el volumen de datos paralelos disponibles y las capacidades computacionales, y sirve como guía para el diseño experimental del presente proyecto.

2.2.7. Modelos base candidatos: análisis comparativo

La selección del modelo multilingüe preentrenado que servirá como base para el ajuste fino constituye una decisión arquitectural central del proyecto. Tres familias de modelos merecen consideración: NLLB-200 de Meta, MADLAD-400 de Google y TranslateGemma de Google

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera DeepMind. A continuación se presenta una comparativa sintética de sus características técnicas en la Tabla 2.

Tabla 2
Comparativa de modelos multilingües candidatos para la adaptación al par Inga-Español

Modelo	Parámetros	Lengua	Quechua	Licenci	Arquitectu	Ajustable
		s	incluido	a	ra	en M4 Max 128 GB
NLLB-200-3.3B (NLLB Team, 2022, 2024)	3.3 mil millones	200	Sí (quy_Latn)	CC BY-NC 4.0	Encoder - decoder	Sí, permite incluso el fine-tuning completo
NLLB-200-distilled-600M	600 millones	200	Sí	CC BY-NC 4.0	Encoder - decoder	Sí, con amplio margen
MADLAD-400-10B (Kudugunta et al., 2023)	10.7 mil millones	450+	Sí (qu)	Apache 2.0	T5	Sí, con ajuste fino eficiente
TranslateGemma-12B (Finkelstein et al., 2026)	12 mil millones	Multilingüe	Parcial	Gemma License	Decoder-only	Sí, con ajuste fino eficiente

Nota. Elaboración propia con base en la documentación técnica publicada por los autores respectivos.

La decisión metodológica del presente proyecto consiste en adoptar **NLLB-200-distilled-600M** como modelo principal para la fase de prototipado rápido, por su menor requerimiento de cómputo y tiempo de iteración, y **NLLB-200-3.3B** como modelo principal para los

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera experimentos finales. La justificación es triple. Primero, NLLB-200 es el modelo dominante en las competencias AmericasNLP de los últimos años, tal como evidencian los trabajos de Garcia Gilabert et al. (2024), Attieh et al. (2024) y DeGenaro y Lupicki (2024), lo que asegura compatibilidad metodológica con el estado del arte. Segundo, incluye explícitamente Quechua Ayacucho (quy_Latn) entre sus 200 lenguas soportadas, habilitando transferencia directa cross-lingual hacia el Inga. Tercero, la versión de 3.3 mil millones de parámetros resulta ajustable de manera completa o mediante LoRA en la estación local disponible para el proyecto (Apple M4 Max con 128 GB de RAM unificada), eliminando la dependencia de plataformas cloud.

2.3. CONCLUSIONES DEL CAPÍTULO

La revisión del estado del arte presentada en este capítulo permite derivar cuatro conclusiones fundamentales que orientan el diseño metodológico del presente trabajo.

Primero, la viabilidad técnica de adaptar modelos de traducción automática multilingüe preentrenados a lenguas indígenas de América Latina mediante transferencia desde parientes lingüísticos está sólidamente documentada. Los resultados del equipo BSC en AmericasNLP 2024 (Garcia Gilabert et al., 2024), así como los de Chen et al. (2024) con QueEn, muestran que el par tecnológico central del proyecto, NLLB-200 como modelo base, ajustado mediante LoRA con transferencia desde Quechua Ayacucho, es competitivo en el estado del arte para variantes del Quechua con cantidades de datos comparables a las disponibles para el Inga.

Segundo, el paradigma de modelos de lenguaje de frontera con recuperación aumentada ha emergido como una alternativa complementaria con propiedades favorables específicas para lenguas de bajos recursos. La "eficiencia de recursos" documentada para Claude por Enis y Hopkins (2024), junto con la evidencia sobre *in-context learning few-shot* de Cahyawijaya, Lovenia y Fung (2024), sustentan la segunda línea experimental del presente trabajo.

Tercero, existe un vacío específico en la literatura que el presente trabajo contribuye a cerrar: no se ha identificado ningún trabajo previo que compare sistemáticamente ambas aproximaciones, ajuste fino eficiente de NMT multilingüe versus modelo de lenguaje de frontera con recuperación aumentada, sobre el mismo par lingüístico de bajos recursos, y

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera
tampoco trabajos que aborden el Inga con cobertura dialectal explícita de Alto Putumayo y Medio Putumayo. Ambas contribuciones constituyen el aporte original del proyecto.

Cuarto, la evaluación de sistemas de traducción automática para lenguas aglutinantes como el Inga requiere métricas que complementen al BLEU con alternativas sensibles a la morfología (chrF++, Popović, 2017) y a la semántica profunda (BERTScore, Zhang et al., 2020; COMET, Rei et al., 2022). La validación humana con hablantes nativos es además indispensable para capturar dimensiones de calidad no reflejadas por las métricas automáticas, tal como enfatizan Ebrahimi et al. (2024) y de Gibert et al. (2025) en los *findings* oficiales de AmericasNLP.

Estas conclusiones justifican la metodología que se expone en el siguiente capítulo, organizada en siete fases que abordan secuencialmente la configuración del entorno, la construcción del corpus bidialectal, el diseño de la base de conocimiento, las dos líneas experimentales centrales del proyecto, la evaluación comparativa rigurosa y el despliegue final.

3. OBJETIVOS CONCRETOS Y METODOLOGÍA DE TRABAJO

3.1. OBJETIVO GENERAL

Desarrollar y evaluar un sistema de traducción automática Inga-Español que combine la adaptación de modelos de traducción automática multilingüe con aproximaciones basadas en recuperación aumentada de información sobre modelos de lenguaje de frontera, con el fin de contribuir a la preservación digital de la lengua Inga del Putumayo.

3.2. OBJETIVOS ESPECÍFICOS

- Del objetivo general se derivan siete objetivos operativos que ordenan el trabajo según las dependencias técnicas naturales del proyecto, desde la preparación del entorno hasta el despliegue de los modelos. Cada uno tiene asociado un criterio de cumplimiento verificable.
- La primera tarea es preparar el entorno de cómputo local en hardware Apple Silicon, con las bibliotecas de procesamiento del lenguaje natural, la aceleración por GPU integrada y la infraestructura mínima de seguimiento de experimentos. El criterio operativo asociado es ejecutar con éxito una inferencia zero-shot de un modelo multilingüe preentrenado, lo que valida que el stack funciona extremo a extremo antes de comprometer tiempo en datos o entrenamiento.
- A continuación viene la construcción del corpus paralelo. Las fuentes disponibles son escasas y heterogéneas: el Nuevo Testamento Inga publicado por Wycliffe, las narrativas orales recopiladas en *Antihua Pacay*, el diccionario Tandioy, la gramática pedagógica de Levinsohn y un apéndice morfosintáctico del proyecto Rosetta. El reto está en extraer, alinear, normalizar y particionar todo esto en conjuntos de entrenamiento, validación y prueba aprovechables. La meta mínima cuantitativa son 5.000 pares paralelos; la cobertura debe alcanzar las dos variantes dialectales del Inga, Alto y Medio Putumayo, aunque el balance entre ambas dependerá de la calidad efectiva de las fuentes de cada lado.
- En paralelo se construye la base de conocimiento lingüístico que alimentará la línea experimental del modelo de lenguaje de frontera. Esta base se estructura

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

deliberadamente en índices separados, no en un único índice mezclado, para que el sistema de recuperación pueda dirigir cada consulta al tipo de conocimiento relevante: el índice léxico para palabras del diccionario, el índice gramatical para reglas morfosintácticas, el índice de ejemplos para pares Inga-español similares semánticamente. Se considera cumplido cuando la base es consultable y cubre al menos 800 entradas léxicas, las reglas gramaticales principales del Inga y una muestra representativa del corpus paralelo.

- El cuarto objetivo es la adaptación de un modelo de traducción multilingüe preentrenado al par Inga-español. La técnica elegida es ajuste fino eficiente en parámetros, que evita reentrenar el modelo completo y aprovecha las representaciones de las lenguas quechuas emparentadas que el modelo ya conoce de su preentrenamiento. La adaptación se considera lograda cuando supera, en el conjunto de prueba, la línea base zero-shot del mismo modelo base sin ajuste.
- La quinta línea de trabajo implementa el pipeline alternativo: un modelo de lenguaje de frontera consume *prompts* estructurados que se construyen dinámicamente recuperando contexto desde los tres índices de la base de conocimiento. El criterio de cumplimiento aquí es funcional más que cuantitativo: el pipeline debe integrar los tres índices, mantener tiempos de inferencia razonables en lote y producir traducciones consistentes en estructura.
- Una vez ambas líneas están operativas, se ejecuta la evaluación comparativa con métricas automáticas estándar (BLEU, chrF++ y BERTScore) y validación cualitativa con hablantes nativos en las dimensiones de adecuación semántica, fluidez gramatical y naturalidad cultural. El informe final debe cubrir al menos cinco configuraciones experimentales con validación humana sobre una muestra representativa de traducciones.
- El cierre del proyecto consiste en empaquetar el sistema resultante como una aplicación local reproducible y documentar el marco metodológico de manera que sea reutilizable por otras lenguas indígenas en situación análoga. El entregable concreto

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera
es un repositorio público con instrucciones de despliegue y un documento metodológico que explicita las decisiones tomadas en cada fase.

3.3. METODOLOGÍA DEL TRABAJO

3.3.1. Enfoque metodológico

El presente trabajo adopta un enfoque de investigación aplicada con diseño experimental comparativo. La estrategia central consiste en desarrollar dos sistemas de traducción en paralelo, uno basado en el ajuste fino eficiente de un modelo multilingüe preentrenado y otro basado en un modelo de lenguaje de frontera con recuperación aumentada de información, y evaluar rigurosamente cuál produce mejores traducciones para el par Inga-Español. La evaluación se realiza con métricas automáticas estandarizadas y con validación humana por hablantes nativos, asegurando la triangulación de las conclusiones.

3.3.2. Fases del proyecto

El trabajo se organiza en siete fases con una correspondencia uno a uno con los objetivos específicos enunciados en la sección 3.2. El detalle pedagógico y técnico de cada fase se resume a continuación; la ejecución concreta se documenta en el Capítulo 4.

La fase inicial es la configuración del entorno de cómputo: instalación de las bibliotecas de NLP (*Transformers*, *PEFT*, *Accelerate*, *sentence-transformers*, *sacrebleu*, *datasets*) sobre Apple Silicon y validación de la aceleración MPS por hardware. Se cierra con una inferencia zero-shot de prueba sobre un modelo multilingüe preentrenado, que sirve como prueba de extremo a extremo de que el stack funciona antes de comprometer tiempo en datos o entrenamiento.

Construir el corpus paralelo es la segunda fase y la más laboriosa de las preparatorias. Se aplica un pipeline de segmentación, detección de idioma por bloque, alineación canónica o heurística según la fuente, normalización ortográfica y partición en conjuntos de entrenamiento, validación y prueba. Las cinco fuentes primarias del Inga descritas en los capítulos 2 y 4 entran en este pipeline, cada una con peculiaridades de formato que obligan a parsers específicos. El proceso completo se ilustra en la Figura 4.

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera




Figura 4

Pipeline de construcción del corpus paralelo Inga-Español

Nota. Elaboración propia.

Tras el corpus se diseña la base de conocimiento para la línea experimental basada en recuperación aumentada. Tres índices independientes: uno léxico derivado del diccionario, uno gramatical derivado de la gramática pedagógica y del apéndice morfosintáctico, y uno de ejemplos paralelos derivado del corpus alineado. La indexación combina embeddings multilingües densos y una base de datos vectorial local. Las estrategias de control de contexto (top-k acotado, umbrales de similitud, presupuestos de tokens, *reranking* opcional con *cross-encoder*) se ajustan para mantener el *prompt* del modelo generativo dentro de límites manejables.

La cuarta fase aborda el ajuste fino eficiente en parámetros del modelo base. Se aprovecha el código de lengua Quechua Ayacucho (quy_Latn) que el modelo ya contempla como punto de partida para la transferencia al Inga, lo cual reduce drásticamente la cantidad de datos paralelos necesarios respecto a entrenar desde cero. Cuando el calendario lo permite, se incluyen experimentos de *ablation* sobre dimensionalidad de los adaptadores, tasa de aprendizaje y augmentación sintética por *back-translation*. La Figura 5 muestra el pipeline.




Figura 5

Pipeline de ajuste fino eficiente del modelo de traducción multilingüe

Nota. Elaboración propia.

En paralelo con la cuarta fase corre la quinta, que implementa la línea LLM más RAG. Un modelo de lenguaje de frontera recibe un *prompt* construido en tiempo de inferencia con el contexto recuperado de los tres índices. El detalle del pipeline aparece en la Figura 6.




Figura 6

Pipeline de traducción basado en modelo de lenguaje de frontera con recuperación aumentada

Nota. Elaboración propia.

La sexta fase es la evaluación comparativa. Cada una de las configuraciones definidas en la Tabla 4 se mide con BLEU, chrF++ y BERTScore sobre el conjunto de validación, complementadas con sesiones de validación humana con hablantes nativos. Los resultados se sintetizan en el Capítulo 4; el análisis cualitativo profundo y la validación humana extendida se reservan para la entrega final del TFM.

Cierra el cronograma la séptima fase, dedicada a empaquetar el sistema como aplicación local replicable y a documentar el marco metodológico como aporte reutilizable.

3.3.3. Cronograma

El cronograma global del proyecto se muestra en la Figura 7. Las fases presentan traslape planificado cuando las dependencias lo permiten: en particular, la construcción del corpus (Fase 2) se inicia en paralelo con la configuración del entorno y se prolonga durante varios meses, alimentando tanto al ajuste fino (Fase 4) como al sistema RAG (Fases 3 y 5) a medida que avanza.

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

Cronograma del TFM — fases y ventanas de ejecución




Figura 7

Cronograma del proyecto, distribuido por fases y fechas

Nota. Elaboración propia.

3.3.4. Infraestructura de cómputo

La infraestructura de cómputo empleada se detalla en la Tabla 5. La decisión de operar sobre hardware local de alta capacidad, en lugar de plataformas cloud, se fundamenta en tres consideraciones: reproducibilidad del entorno, soberanía de los datos lingüísticos de la comunidad Inga y predictibilidad del costo del proyecto. La API del modelo de lenguaje de frontera se utiliza únicamente para la línea experimental correspondiente.

Tabla 3

Infraestructura de cómputo del proyecto

Recurso	Especificación	Uso principal
Estación de trabajo local	Apple M4 Max, 128 GB RAM unificada	Inferencia y ajuste fino eficiente del modelo multilingüe; indexación y recuperación vectorial; ejecución de todos los notebooks del proyecto.
API de modelo de lenguaje de frontera	Anthropic (modelo vigente al cierre de la investigación)	Pipeline de traducción con recuperación aumentada; línea experimental LLM.

Almacenamiento vectorial local	FAISS o ChromaDB (decisión técnica en Fase 3)	Indexación de la base de conocimiento lingüístico del Inga.
Control de versiones	Git y GitHub	Código fuente, notebooks, documentación del proyecto.

Nota. Elaboración propia.

3.3.5. Configuraciones experimentales a evaluar

La Fase 6 evalúa al menos cinco configuraciones experimentales, cuyo diseño se resume en la Tabla 4. Las configuraciones permiten aislar el efecto de cada técnica central (ajuste fino, recuperación aumentada, su combinación) y comparar líneas de base zero-shot con las aproximaciones adaptadas específicamente al Inga.

Tabla 4
Configuraciones experimentales a evaluar en la Fase 6 del proyecto

Config.	Modelo	Técnica	Recursos utilizados
A	Modelo multilingüe base (p. ej., NLLB-200-3.3B)	Traducción zero-shot con código de lengua más cercano (quy_Latn)	N/A
B	Modelo multilingüe base	Ajuste fino eficiente (LoRA) sobre corpus Inga bidialectal	Corpus paralelo AP + MP
C	Modelo de lenguaje de frontera	Prompt zero-shot	N/A
D	Modelo de lenguaje de frontera	Recuperación aumentada multi-índice (léxico, gramatical, ejemplos)	Base de conocimiento del Inga

E	Modelo multilingüe ajustado (config. B)	Recuperación aumentada aplicada en inferencia	Corpus + base de conocimiento
---	---	---	-------------------------------

4. DESARROLLO ESPECÍFICO DE LA CONTRIBUCIÓN

Este capítulo documenta la implementación de las Fases 1 a 6 del proyecto, desde la configuración del entorno experimental hasta la evaluación comparativa de las cinco configuraciones definidas en la Tabla 4. Cada sección reporta tanto la decisión metodológica adoptada como la evidencia cuantitativa y cualitativa de su ejecución.

4.1. CONFIGURACIÓN DEL ENTORNO COMPUTACIONAL

Sobre la estación local Apple M4 Max (128 GB de memoria unificada, macOS Darwin 25.3.0) se montó el entorno experimental con Python 3.11 gestionado mediante uv. El proyecto se reorganizó como paquete reproducible con `pyproject.toml`, `lockfile (uv.lock)` y archivo de variables de entorno separado (`.env.example`) para las credenciales de APIs externas. Las librerías centrales utilizadas son *transformers*, *peft* y *accelerate* para el ajuste fino de modelos multilingües; *sentence-transformers* y la SDK oficial *google-genai* para los embeddings densos; *anthropic* para el modelo de lenguaje de frontera; *lancedb* para el almacenamiento vectorial; y *sacrebleu* y *bert-score* para la evaluación automática. La aceleración por hardware Metal Performance Shaders (MPS) se validó en una inferencia zero-shot del modelo `facebook/nllb-200-distilled-600M` sobre el par Español-Quechua Ayacucho (`spa_Latn` a `quy_Latn`), que constituye el criterio de cierre formal de esta fase. El detalle del entorno se preserva en el Notebook 00 del repositorio, referenciado en el Anexo A.

El entorno se declara por completo en `pyproject.toml` y queda congelado en `uv.lock`, de modo que la reconstrucción no depende de qué versiones estuvieran instaladas el día del experimento. Las piezas que determinan los resultados son cuatro: PyTorch con el backend MPS para el entrenamiento local, la biblioteca *peft* en su versión 0.19.1 para los adaptadores LoRA, *sacrebleu* y *bert-score* para las métricas, y *lancedb* como motor de los índices vectoriales. Las dos dependencias de servicios externos, *anthropic* y *google-genai*, son las

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera únicas que exigen credenciales y por tanto las únicas que impiden reproducir el trabajo de forma completamente offline.

La elección de trabajar sobre una estación local, y no sobre GPU alquilada en la nube, no es solo una cuestión de coste. Los 128 GB de memoria unificada del Apple M4 Max permiten cargar el modelo base de 600 millones de parámetros y entrenar el adaptador sin cuantización ni acumulación de gradientes, y el entrenamiento completo cabe en menos de media hora. Esto tiene una consecuencia que interesa al propósito del proyecto: el pipeline de ajuste fino de este trabajo puede ejecutarse en un portátil de gama alta, sin infraestructura especializada, lo que lo pone al alcance de una comunidad o de una universidad regional sin presupuesto de cómputo. La línea basada en el modelo de frontera, en cambio, sí depende de una API de pago y esa asimetría se discute en el Capítulo 5.

4.2. CONSTRUCCIÓN DEL CORPUS PARALELO

La construcción del corpus paralelo Inga-Español se apoya en cinco fuentes primarias previamente extraídas a formato Markdown mediante reconocimiento óptico de caracteres. El inventario consolidado se muestra en la Tabla 5.

Tabla 5
Inventario de recursos lingüísticos primarios utilizados en la construcción del corpus

Recurso	Dialecto	Páginas	Registro	Tipo de alineación	Unidades detectadas
Diccionario Inga (Tandioy Jansasoy et al., 1997)	AP + MP (marcado)	177	Léxico	N/A	4.900 entradas

<i>Gramática Pedagógica del Inga (Levinsohn y Mongui)</i>	AP principalmente	228	Didáctico	N/A	560 bloques
Apéndice morfosintáctico (Rosetta Project)	N/A	26	Técnico	N/A	45 bloques
<i>El Nuevo Testamento en Inga (Wycliffe Bible Translators, 2012)</i>	AP (probable)	595	Bíblico-literario	Versículo	6.083 versículos
<i>Antihua Pacay Gentecunapa Parlocuna (Jamioy Yanangona de Peña, 1985)</i>	MP (Mocoa)	68	Narrativo oral	Bloque	86 pares exploratorios

Nota. Elaboración propia a partir de los notebooks 03 a 07 de este trabajo. La cifra total de páginas OCR asciende a 1.094.

Extracción de las fuentes primarias. Las cinco fuentes primarias del Inga existen únicamente como documentos PDF, varios de ellos digitalizaciones de materiales impresos de las décadas de 1980 y 1990. Antes de cualquier alineación hubo que convertir esos PDF en texto procesable, y la decisión de diseño en este punto condiciona todo lo que viene después. En lugar de extraer texto plano, se optó por un reconocimiento óptico que preservara la estructura del documento: encabezados, tablas, saltos de página y disposición en columnas.

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

La extracción se realizó con `mistral-ocr-extractor`, una herramienta de línea de comandos desarrollada por el propio autor de este trabajo (Santos, <https://github.com/wsantosai/mistral-ocr-extractor>) que procesa por lotes archivos PDF e imágenes apoyándose en la API de OCR de Mistral. Disponer de una herramienta propia, en lugar de un servicio cerrado, permitió controlar el formato de salida y reejecutar la extracción cuantas veces hizo falta sin coste de reimplementación. La herramienta produce un archivo Markdown por documento, con un frontmatter de metadatos y marcadores de página de la forma `<!-- Page N -->` intercalados en el texto, y extrae además las imágenes embebidas a una subcarpeta. Los archivos depositados en `datos/ocr/` son la salida directa de ese proceso, sin edición manual posterior, una condición que se mantuvo de forma deliberada para que la extracción fuera reproducible y auditable: cualquiera que reejecute el pipeline parte del mismo material.

La elección de Markdown como formato intermedio no es accesorio. Los parsers estructurados de los notebooks posteriores se apoyan precisamente en las marcas que el OCR conserva. El reconstructor del Nuevo Testamento Inga (Notebook 03) usa los encabezados y los marcadores de página para recuperar la tupla canónica libro-capítulo-versículo; la indexación del diccionario (Notebook 08) aprovecha la estructura de entradas que el OCR mantiene como listas y tablas. Una extracción a texto plano habría borrado esas señales y habría obligado a una reconstrucción mucho más frágil.

El reto principal fue la heterogeneidad. Las cinco fuentes no comparten ni formato ni calidad de origen: el Nuevo Testamento de Wycliffe son 595 páginas con estructura versicular regular; el Diccionario Inga, 177 páginas de entradas bilingües a doble columna con marcas dialectales; la gramática pedagógica de Levinsohn, 228 páginas que mezclan prosa explicativa con ejemplos glosados; el apéndice morfosintáctico Rosetta, 26 páginas de tablas densas; y la cartilla Antihua Pacay, 68 páginas de narrativa en párrafos largos. Las 1.094 páginas resultantes, inventariadas en la Tabla 5, alimentan de forma desigual el corpus: el material con estructura regular se convierte en pares paralelos con facilidad, mientras que la narrativa libre, como se documenta en la subsección de resultados negativos, se resiste a la alineación oracional.

Hay además una dimensión de licenciamiento que conviene anticipar aquí. Las extracciones se conservan en un repositorio privado solo para garantizar la reproducibilidad de los notebooks, porque las fuentes tienen condiciones dispares: el Nuevo Testamento de Wycliffe se distribuye bajo CC BY-NC-ND 3.0, cuya cláusula de no derivados hace cuestionable la redistribución pública de una extracción OCR; los materiales de SIL International exigen cita académica; y el Diccionario Inga requiere autorización del Comité de Educación Inga de la Organización Musu Runakuna. Estas restricciones se retoman en las consideraciones éticas del trabajo.

4.2.1. Reextracción estructurada del Nuevo Testamento en Inga

El OCR original del Nuevo Testamento Wycliffe presenta tres tipos de señal aprovechables para reconstruir la estructura libro-capítulo-versículo: cabeceras de página en mayúsculas con el nombre del libro y el número de capítulo (con notación LIBRO X, Y cuando la página cubre una transición de capítulo); marcadores de versículo en caracteres Unicode superíndice, concatenables como ¹² o combinados con guion como ⁴⁻⁵ para versículos fusionados; y dígitos ASCII intercalados en el cuerpo del texto. El parser desarrollado en el Notebook 03 recorre el documento línea por línea manteniendo el estado actual de libro y capítulo, descarta encabezados de pericope (que el OCR marca con el mismo nivel de heading que las divisiones de libro) y aplica un resolutor contextual para los casos ambiguos: el heading # SAN JUAN, por ejemplo, puede corresponder al evangelio o a las epístolas 1, 2 o 3 Juan según cuál de esos libros ya se haya procesado vía cabeceras de página.

El resultado es una salida JSONL con 6.083 versículos únicos del NT Inga, equivalentes al 76,5% del canon de 7.958. La distribución por libro se mantiene relativamente uniforme entre el 70% y el 85% de cobertura, con caídas en los libros muy cortos (2 Juan, 3 Juan) cuyo OCR fragmenta los pocos marcadores de versículo disponibles.

4.2.2. Extracción del Nuevo Testamento en español

La selección del corpus paralelo en español requiere conciliar dos restricciones competitivas: que la traducción sea culturalmente próxima al uso del Putumayo y que sea redistribuible para preservar el compromiso del proyecto con la liberación abierta de los recursos. La Biblia

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera Latinoamericana, aunque es la traducción más leída en el sur de Colombia, mantiene copyright vigente de Editorial Verbo Divino hasta aproximadamente 2074 y por tanto no puede formar parte de un corpus paralelo abierto. La traducción de Torres Amat (1832), católica y en dominio público verificado, sólo está disponible como escaneos antiguos de calidad de OCR variable, con problemas de columnas mezcladas y texto latino paralelo que reducirían la tasa de alineación esperada a menos del 80%. La Reina-Valera 1909, en cambio, está disponible en formato USFM estructurado a través del distribuidor eBible.org, con dominio público explícito y certificación de procedencia. Aunque es una traducción protestante, la estructura libro-capítulo-versículo del Nuevo Testamento es idéntica al canon católico, lo que permite una alineación sin pérdida estructural con el NT Inga (de origen también protestante por su traductor, Wycliffe).

El Notebook 04 procesa los 27 archivos USFM del NT Reina-Valera 1909 eliminando el marcado anotativo (etiquetas Strong, notas al pie, referencias cruzadas y palabras añadidas por el traductor entre \add...\add*). El resultado preserva 7.955 de los 7.958 versículos canónicos (99,96%), un 23 puntos por encima de la cobertura alcanzada por el parser del NT Inga, lo cual era esperable: el USFM es texto digital nativo, mientras que el Inga es OCR sobre un PDF impreso.

4.2.3. Alineación canónica versículo a versículo

El Notebook 05 ejecuta un *inner join* exacto entre las dos salidas JSONL utilizando la tupla (libro, capítulo, versículo) como clave. El total de pares resultantes es 5.680, lo que equivale al 93,3% de los versículos disponibles en la versión Inga: los falsos positivos del parser OCR (números que parecen marcadores pero no son versículos canónicos) se filtran naturalmente al no encontrar coincidencia en el lado español. Sobre esa salida se aplican tres filtros de calidad: longitud mínima de cinco palabras en ambos lados, relación máxima de longitudes de cinco a uno entre versiones (descarta desalineamientos obvios) y exclusión de versículos mayoritariamente numéricos. El corpus paralelo final contiene 5.589 pares con una longitud media de 21,2 palabras en Inga y 20,7 en español, y una relación media de longitudes de 1,44. Los 27 libros del Nuevo Testamento están representados.

El proceso parte de 6.779 registros extraídos del Nuevo Testamento Inga, que se reducen a 6.091 tras eliminar duplicados de la tupla (libro, capítulo, versículo) producidos por el parser, y de 7.955 versículos de la Reina-Valera de 1909. El join exacto sobre esa tupla devuelve 5.680 pares, lo que equivale al 93,3 por ciento de los versículos Inga disponibles y al 71,4 por ciento de los españoles. La diferencia entre ambas tasas se explica sola: la edición Inga no cubre el Nuevo Testamento completo con la misma granularidad de versículo, de modo que el español aporta más material del que puede emparejarse.

Sobre esos 5.680 pares se aplican tres filtros de calidad, todos ellos deliberadamente conservadores. Se descarta el par cuyo texto, en cualquiera de las dos lenguas, tenga menos de cinco palabras, porque los fragmentos muy cortos suelen ser restos de encabezado y no oraciones. Se descarta también el par en el que más de la mitad de las palabras sean dígitos, que es la firma de una referencia cruzada mal segmentada. Y se descarta el par cuya razón de longitud entre las dos lenguas supere el factor cinco, indicio de que la correspondencia canónica emparejó un versículo con otro que no le corresponde. Los dos primeros filtros eliminan 37 pares y el tercero 74, con cierto solapamiento entre ambos conjuntos, y el corpus queda en 5.589 pares.

Conviene ser explícito sobre lo que estos filtros no pueden hacer. Detectan desajustes groseros de longitud, pero no detectan un emparejamiento incorrecto entre dos versículos de longitud parecida. Si la numeración de la edición Inga se desplaza respecto a la española en un versículo, el par resultante pasa los tres filtros sin problema y entra al corpus con una traducción que no corresponde. En el apartado 4.6.5 se documenta un caso de este tipo detectado en la muestra de evaluación, y es la razón por la que la tasa de alineación del 93,3 por ciento debe leerse como una cota superior de la calidad real del emparejamiento.

4.2.4. Antihua Pacay como recurso exploratorio

La cartilla narrativa *Antihua Pacay Gentecunapa Parlocuna* es la única fuente primaria disponible del dialecto Medio Putumayo y por tanto es estratégicamente relevante para la cobertura bidialectal del proyecto. El Notebook 06 segmenta el documento en sus dos mitades (un bloque continuo en Inga seguido por un bloque parcial en español) e intenta alinear las historias por orden de aparición. Sólo la primera de las seis historias del documento dispone

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera de traducción al español, y la alineación oración a oración por índice presenta desfase significativo (91 oraciones en Inga frente a 102 en español). El resultado, 86 pares con calidad heterogénea, se documenta pero queda fuera del corpus de entrenamiento empleado en este estudio. La alineación correcta requiere un alineador semántico basado en embeddings multilingües, técnica que se identifica como vía de extensión natural del trabajo.

4.2.5. Particiones del corpus

El Notebook 07 unifica las salidas y produce las particiones train, val y test en proporción 80/10/10 mediante un *shuffle* aleatorio con semilla 42. La estratificación por libro, considerada inicialmente, no es viable porque dos libros del NT (2 Juan con 5 pares y 3 Juan con 6 pares en el corpus alineado) no tienen suficientes muestras para distribuirse en tres particiones disjuntas. El *shuffle* aleatorio cubre los 27 libros en train, 25 en val y 26 en test, con los faltantes correspondiendo a los dos libros mencionados. Las cifras absolutas son 4.471 pares de entrenamiento, 558 de validación y 560 de prueba. La distribución resultante por libro y partición se muestra en la Figura 8.




Figura 8

Distribución del corpus paralelo Inga-español por libro y partición

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

Nota. Elaboración propia a partir del Notebook 07. Las tres particiones se generan por shuffle aleatorio con semilla 42 en proporción 80/10/10; la dominancia visual de Lucas, Hechos y Mateo refleja el desbalance natural del Nuevo Testamento, donde estos tres libros concentran el 41% de los versículos del canon.

El desglose por dialecto de las tres particiones se detalla en la Tabla 6.

Tabla 6

Distribución del corpus paralelo train/val/test por dialecto

Partición	AP (Alto Putumayo)	MP (Medio Putumayo)	Total
Train	4.512	0	4.512
Val	564	0	564
Test	565	0	565
Total	5.641	0	5.641

Nota. Elaboración propia. La columna MP queda en cero porque la alineación de Antihua Pacay se posterga a la Entrega Final como se explica en la sección 4.2.4.

4.2.6. Material descartado y sus razones

No todo el material que se procesó entró en el corpus final. Dos fuentes se trabajaron hasta una fase avanzada y luego se dejaron fuera, y vale la pena dejar constancia de por qué: las decisiones de exclusión delimitan el alcance del trabajo y evitan que el lector suponga una cobertura que el corpus no tiene.

El primer descarte fue el Antiguo Testamento. A partir de la misma fuente Wycliffe se extrajeron y estructuraron 794 versículos del Antiguo Testamento en Inga (Notebook 12), y se intentó alinearlos con la Reina-Valera 1909 siguiendo el mismo procedimiento canónico que funcionó con el Nuevo Testamento. El proceso produjo 399 pares candidatos (Notebook 13), pero la alineación resultó poco fiable y el material se mantuvo como exploratorio, sin incorporarlo al corpus de entrenamiento ni de evaluación. La consecuencia práctica es que el sistema se entrena y se mide únicamente sobre Nuevo Testamento y la Constitución, y no cubre el registro del Antiguo Testamento.

El segundo descarte fue la cartilla narrativa Antihua Pacay, un material valioso por dos razones: es del dialecto Medio Putumayo, ausente en el resto del corpus, y es narrativa tradicional, no traducción bíblica. El problema fue estructural. De los 284 párrafos detectados en la cartilla, solo 4 admitían una alineación limpia bloque a bloque entre el Inga y su versión en español. Forzar la correspondencia produjo 86 pares (Notebook 06), pero de calidad demasiado baja para entrenar, porque la narrativa libre no respeta la correspondencia oración a oración que sí ofrece el texto bíblico versificado. Se decidió dejarla fuera del entrenamiento. Este resultado negativo es informativo: confirma que la estrategia de alineación canónica, eficaz con material versificado, no se traslada sin más a la prosa narrativa, y motiva de forma directa la línea de trabajo futuro sobre un alineador semántico basado en embeddings multilingües, que no depende de la coincidencia estructural.

Ambos descartes apuntan al mismo cuello de botella del proyecto: la escasez de material Inga con estructura paralela explotable. Hay texto Inga disponible, pero convertirlo en pares de traducción fiables exige o bien una correspondencia canónica previa, como la versificación bíblica, o bien una alineación semántica que este trabajo deja planteada pero no implementa.

4.2.7. Perfil estadístico del corpus

El corpus final reúne 5.641 pares, de los cuales 5.589 provienen del Nuevo Testamento y 52 de la Constitución de 1991. Conviene mirar su composición interna, porque de ella se derivan varias decisiones técnicas del resto del capítulo y también varias de sus limitaciones.

La distribución por libro es marcadamente desigual, como muestra la Tabla 7. Los cuatro evangelios y los Hechos de los Apóstoles concentran 3.338 pares, casi el sesenta por ciento del total, mientras que en el otro extremo hay libros que apenas contribuyen: 2 Juan y 3 Juan aportan cinco pares cada uno. Esta asimetría tiene una consecuencia inmediata sobre el diseño experimental. La partición estratificada por libro, que habría sido la opción natural para garantizar que las tres particiones cubrieran el mismo reparto temático, resulta inviable cuando existen clases con cinco elementos, porque una estratificación 80/10/10 sobre cinco pares no reparte nada. Por eso el Notebook 07 recurre a una partición aleatoria simple con semilla 42, decisión que se documenta aquí con su motivo y no como una preferencia arbitraria.

Las longitudes de las dos caras del corpus son más parecidas de lo que cabría esperar entre una lengua aglutinante y una lengua flexiva. El texto Inga suma 119.174 palabras y el español 116.584, con medias de 21,13 y 20,67 palabras por par. La razón de longitud entre ambas caras tiene mediana 0,93, es decir, la versión Inga de un versículo típico es ligeramente más corta que la española, lo que concuerda con una morfología que empaqueta en sufijos lo que el español despliega en preposiciones y artículos. La media de esa misma razón, en cambio, es 1,07, y esa discrepancia entre media y mediana delata la existencia de una cola de pares donde el Inga se alarga desproporcionadamente. El par más extremo tiene 131 palabras en Inga frente a un máximo de 63 en español. Esos casos suelen corresponder a versículos donde la traducción Inga es más parafrástica que literal, y son candidatos naturales a introducir ruido en el entrenamiento.

El corpus es homogéneo en un sentido que conviene no perder de vista: los 5.641 pares pertenecen al dialecto Alto Putumayo y proceden, salvo 52 excepciones, de un único texto religioso traducido por un único equipo. Esa homogeneidad facilita el aprendizaje, porque el registro y la ortografía son consistentes, y al mismo tiempo limita la generalización, porque el sistema aprende a traducir el Inga de la Biblia de Wycliffe antes que el Inga que se habla en el Putumayo.

Tabla 7

Distribución del corpus paralelo por libro (diez primeros) y fuente

Libro o fuente	Pares	Porcentaje del corpus
Lucas	794	14,1
Hechos	704	12,5
Mateo	697	12,4
Juan	635	11,3
Marcos	508	9,0

Romanos	346	6,1
1 Corintios	304	5,4
Apocalipsis	249	4,4
Hebreos	226	4,0
2 Corintios	180	3,2
Resto del Nuevo Testamento (17 libros)	946	16,8
Constitución de 1991	52	0,9
Total	5.641	100,0

Nota. Elaboración propia a partir de datos/corpus_paralelo.jsonl. El corpus abarca 28 libros del Nuevo Testamento. Los dos menos representados, 2 Juan y 3 Juan, aportan cinco pares cada uno.

4.3. BASE DE CONOCIMIENTO E INDEXACIÓN VECTORIAL

El sistema de recuperación aumentada del eje LLM se sustenta en tres índices vectoriales independientes alojados en LanceDB. La elección de LanceDB como motor de almacenamiento se debe a tres consideraciones: es una base de datos vectorial *embedded*, sin servicio externo ni clave de API, lo que mantiene la reproducibilidad y elimina costos recurrentes; usa un formato columnar inspeccionable directamente con herramientas de análisis de datos; y maneja sin sobrecarga el volumen estimado del proyecto, del orden de diez mil vectores. Los embeddings se calculan con `gemini-embedding-001`, configurado con `output_dimensionality=768` para reducir el espacio de almacenamiento sin pérdida material de calidad, e implementan reintento exponencial con throttling de 1,2 segundos entre lotes de 50 textos para respetar el límite de 3.000 peticiones por minuto del *tier* de pago de la API.

El **índice léxico** se construye en el Notebook 08 a partir del *Diccionario Inga*. La extracción original del proyecto recuperaba sólo el lema y la categoría gramatical de cada entrada,

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera perdiendo la glosa en español. El parser de este trabajo recupera las definiciones completas, incluyendo marcadores dialectales y referencias cruzadas, y produce 4.900 entradas estructuradas. Cada entrada se indexa con la composición lema (categoría): glosa para que el embedding capture simultáneamente la palabra Inga y su semántica castellana.

El **índice gramatical** se construye a partir de la *Gramática Pedagógica del Inga* de Levinsohn y del apéndice morfosintáctico Rosetta, segmentando los documentos en bloques de párrafo con al menos treinta palabras y descartando líneas residuales del OCR (numeración de páginas, encabezados sueltos). El resultado son 560 chunks de la gramática y 45 del apéndice, un total de 605 unidades de conocimiento gramatical.

El **índice de ejemplos** indexa los 4.512 pares del *split* de entrenamiento por el texto Inga, devolviendo en la consulta también la traducción al español para inyectarla como ejemplo *few-shot* en el prompt del modelo de lenguaje de frontera. Para soportar la traducción en dirección inversa, español a Inga, se construye adicionalmente un cuarto índice (ejemplos_es) con los mismos pares pero indexados por el texto español. Esta duplicación es necesaria porque la similitud vectorial se calcula sobre el texto de la *query*, que debe estar en la lengua de origen.

La arquitectura resultante del sistema de recuperación se muestra en la Figura 9.

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera




Figura 9

Arquitectura del sistema RAG implementado

Nota. Elaboración propia. El retriever consulta los tres índices en paralelo y devuelve top-k de cada uno. Para la dirección inversa, el índice de ejemplos se conmuta dinámicamente a ejemplos_es.

La validación cualitativa del retriever se ejecuta sobre tres queries representativas. La palabra *wasi* (casa) recupera del índice léxico las entradas *casa* (s): *wasi* y *wasi* (s): *casa*; del índice gramatical, bloques que explican el uso de *huasi* con sufijos de caso (*huasi cancha*, *huasi ucu*); del índice de ejemplos, tres versículos del NT donde aparece la palabra. La consulta *imasa parlangapa* (cómo decir) recupera las entradas léxicas *imasa* y *idioma* junto con tres bloques de la gramática que explican el uso de *imasa* como marcador comparativo, además de versículos que ilustran su uso. Una oración completa, *Taita Diuska runakunata kuianmi*, recupera entradas léxicas tangenciales (la palabra *taita* y compuestos relacionados) pero sí encuentra ejemplos paralelos semánticamente cercanos sobre el amor de Dios en las epístolas. Esta asimetría es esperable: la similitud semántica entre una oración completa y una entrada de diccionario es necesariamente baja, y la utilidad real del índice léxico se manifiesta en las traducciones de palabras sueltas.

Dos decisiones de la indexación merecen justificarse porque condicionan lo que el recuperador puede encontrar. La primera es la dimensionalidad de los vectores. El modelo *gemini-embedding-001* produce por defecto embeddings de 3.072 dimensiones, y en este

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera trabajo se reducen a 768 mediante el parámetro `output_dimensionality`. La reducción responde a una razón práctica: cuatro índices que suman 14.529 registros ocupan en disco 127 MB con vectores de 768 dimensiones, y multiplicar por cuatro ese tamaño no aportaría precisión apreciable en una búsqueda sobre colecciones de este orden, donde el cuello de botella no es la capacidad de representación sino la calidad de lo indexado.

La segunda es la segmentación de la gramática. Los dos recursos gramaticales se trocean en 605 fragmentos, 560 procedentes de la gramática pedagógica de Levinsohn y Mongui y 45 del apéndice morfosintáctico. Ese troceo se hace por longitud y no por unidad de sentido, que es la vía rápida y también la más imperfecta: una regla gramatical puede quedar separada de los ejemplos que la ilustran, y el recuperador entregar entonces la mitad útil de una explicación. El efecto de esta decisión, agravado por el truncamiento posterior a 400 caracteres que se describe en el apartado 4.5.3, se observa en las consultas de sondeo del apartado 4.3.1.

El acceso a la API de embeddings se realiza por lotes de 50 textos con una espera de 1,2 segundos entre lotes y hasta cinco reintentos con retroceso exponencial. Estos parámetros no tienen interés teórico, pero son los que hacen que la indexación de 14.529 registros termine sin errores de límite de tasa, y se consignan porque forman parte de lo que hay que reproducir para obtener los mismos índices.

4.3.1. Validación cualitativa de la recuperación

Antes de medir la calidad de las traducciones conviene comprobar que el componente de recuperación hace lo que se espera de él. Un sistema RAG puede fallar en dos lugares distintos y el error se ve igual desde fuera: puede que el generador traduzca mal, o puede que el recuperador le entregue un contexto inútil y el generador simplemente lo ignore. Por eso el Notebook 08 cierra con una batería de tres consultas de sondeo, una por cada nivel de dificultad, cuyas salidas quedaron guardadas en el propio notebook.

La primera consulta es una palabra aislada, wasi (casa). El índice léxico devuelve como primeras tres entradas casa (s): wasi, wasi (s): casa y wasi kancha (s): patio de la casa. El índice gramatical recupera fragmentos de la gramática de Levinsohn que utilizan huasi como ejemplo para explicar los posposicionales cancha (fuera de) y ucu (dentro de). La recuperación léxica y

la gramatical funcionan aquí como se esperaba: la primera devuelve el lema exacto en ambas direcciones de consulta y la segunda devuelve reglas donde la palabra aparece en uso.

La segunda consulta es una locución, imasa parlangapa (cómo decir). El interés de este caso está en el índice gramatical, que devuelve tres pasajes de Levinsohn dedicados precisamente al comportamiento de imasa: su uso para expresar semejanza con una acción, su frecuencia en interrogativas y su coocurrencia con el infinitivo en -sca. Es el tipo de conocimiento que un modelo de lenguaje de frontera no puede tener memorizado para el Inga y que solo puede llegarle por el contexto.

La tercera consulta es una oración completa, Taita Diuska runakunata kuianmi (Dios ama a las personas). El índice de ejemplos devuelve Efesios 2:4, 1 Juan 5:2 y 1 Juan 4:20, los tres versículos sobre el amor de Dios, lo que confirma que la búsqueda semántica sobre embeddings opera a nivel de significado y no de coincidencia de superficie.

La misma batería expone dos debilidades que conviene registrar. En la tercera consulta, el índice léxico devuelve entre sus tres primeras entradas panela (s): dusi, miski, que no guarda relación con la oración consultada: cuando la consulta es una oración entera y no un lema, el índice léxico pierde precisión porque el embedding de la oración no se parece al embedding de ninguna entrada de diccionario en particular. En la primera consulta ocurre algo distinto y más incómodo. Entre los ejemplos recuperados para wasi aparece Marcos 6:38, cuyo texto Inga menciona efectivamente wasi pero cuyo texto español alineado habla de panes y peces, sin mencionar ninguna casa. El par recuperado es correcto respecto al índice y erróneo respecto al contenido: es ruido de alineación del corpus, heredado de la correspondencia canónica versículo a versículo, que la recuperación no puede corregir y que se traslada intacto al prompt. Este punto se retoma en el apartado 4.6.5.

4.4. ADAPTACIÓN DE NLLB-200 MEDIANTE LORA BIDIRECCIONAL

Contribución de William Santos.

La adaptación de **NLLB-200-distilled-600M** al par Inga-español se ejecutó mediante adaptadores de bajo rango (LoRA) insertados sobre las proyecciones de consulta y valor (q_{proj} , v_{proj}) de las capas de atención del transformador. El entrenamiento corrió en

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera una sola pasada sobre el corpus paralelo duplicado en ambas direcciones, de modo que un único adaptador sirve para inferir Inga-español o español-Inga según los códigos `src_lang` y `tgt_lang` que se pasen al tokenizador en inferencia. La duplicación del corpus de 4.512 a 9.024 ejemplos permitió compartir representaciones entre las dos direcciones sin necesidad de mantener dos adaptadores separados.

La configuración hiperparamétrica del entrenamiento se resume en la Tabla 8. La instrumentación utilizó las librerías *transformers*, *peft* y *accelerate* sobre Python 3.11 con backend Metal Performance Shaders. El procedimiento completo se documenta en el Notebook 09 del repositorio del proyecto, referenciado en el Anexo A.

Tabla 8

Hiperparámetros del entrenamiento LoRA


Hiperparámetro	Valor
Modelo base	facebook/nllb-200-distilled-600M
Código fuente Inga	quy_Latn (Quechua Ayacucho como transferencia)
Código destino español	spa_Latn
Rango LoRA (r)	16
Factor de escala (alpha)	32
Dropout LoRA	0,1
Módulos objetivo	q_proj, v_proj
Optimizador	AdamW
Tasa de aprendizaje	3e-4

Warmup steps	100
Epochs	3
Batch size por dispositivo	8
Longitud máxima de secuencia	128 tokens
Dispositivo	Apple M4 Max + MPS

Nota. Elaboración propia. El corpus de entrenamiento se duplica de 4.512 a 9.024 ejemplos para cubrir ambas direcciones de traducción.

La configuración de LoRA introdujo 2,36 millones de parámetros entrenables, equivalentes al 0,38 % de los 615 millones de parámetros totales del modelo base. Los pesos del adaptador resultante ocupan 9,4 megabytes, frente a los 2,4 gigabytes del modelo NLLB completo, lo que confirma la ventaja de eficiencia en almacenamiento y portabilidad que motiva esta familia de técnicas (Hu et al., 2022; Su et al., 2024). El tiempo total de entrenamiento sobre la estación local fue de aproximadamente 47 minutos para los 3 epochs y 3.384 steps de optimización.

La evolución de la función de pérdida durante el entrenamiento se muestra en la Figura 10. La pérdida de entrenamiento descendió de un valor inicial de 10,71 a 6,00 en los 3.384 steps totales, mientras que la pérdida de validación, evaluada al final de cada epoch, registró 6,05, 5,97 y 5,94 respectivamente. La convergencia entre las dos curvas, sin separación apreciable entre entrenamiento y validación, indica que el modelo no incurre en sobreajuste sobre el corpus disponible; sin embargo, la pérdida absoluta sigue siendo alta para los estándares de la traducción automática neuronal estándar, lo que sugiere que el adaptador alcanza el régimen lineal del proceso de aprendizaje pero no llega al punto de saturación que permitiría una calidad de traducción comparable a pares lingüísticos de alto recurso. Esta limitación se discute en relación con el tamaño efectivo del corpus en el Capítulo 5.

**Figura 10***Curva de loss del entrenamiento LoRA bidireccional*

Nota. Elaboración propia a partir del Notebook 09. La curva azul muestra la pérdida de entrenamiento muestreada cada 20 steps. Los puntos rojos marcan la pérdida de validación al final de cada epoch.

La inspección cualitativa de las traducciones producidas por el adaptador revela un comportamiento asimétrico entre las dos direcciones. En la dirección Inga-español el modelo genera oraciones gramaticalmente correctas y semánticamente plausibles para versículos del Nuevo Testamento, aunque con desviaciones léxicas frecuentes respecto a la referencia. En la dirección español-Inga, en cambio, el decodificador entra en un modo de repetición patológica para más del 40 % de las oraciones del *val set*: secuencias del tipo "iapa iapa iapa..." o "suglla suglla..." se prolongan hasta agotar el presupuesto de tokens, indicando que el modelo no ha logrado aprender una distribución de generación coherente para la lengua de bajos recursos a partir de los 4.512 pares disponibles. Este modo de fallo es conocido en la literatura sobre traducción a lenguas con datos extremadamente escasos y ha sido reportado tanto por Garcia Gilabert et al. (2024) como por DeGenaro y Lupicki (2024).

4.4.1. Lectura de la curva de entrenamiento

Los hiperparámetros del adaptador quedaron fijados en `adapter_config.json`: rango r igual a 16, factor de escala α igual a 32, dropout de 0,1 y aplicación restringida a las matrices de

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera
proyección de consulta y de valor de los bloques de atención, q_proj y v_proj . El entrenamiento corrió tres épocas completas sobre los 9.024 ejemplos bidireccionales, lo que da 3.384 pasos de optimización con tamaño de lote 8, tasa de aprendizaje pico de $3e-4$ y calentamiento lineal durante los primeros 100 pasos. El proceso tardó 1.606 segundos, es decir 26,8 minutos, sobre la GPU integrada del equipo mediante el backend MPS, a un ritmo de 16,86 ejemplos por segundo. El adaptador resultante ocupa 9,4 megabytes frente a los 2,46 gigabytes del modelo base, que es el argumento económico de LoRA y la razón por la que este experimento cabe en un portátil.

La curva de pérdida de la Figura 10 admite una lectura que conviene hacer explícita, porque condiciona la interpretación de los resultados del apartado 4.6. La pérdida de entrenamiento arranca en 10,71 en el paso 20 y cae a 6,01 en el paso 3.380, con un mínimo de 5,92. La caída no está repartida de manera uniforme: casi toda ocurre en la primera época. La pérdida de validación lo confirma con claridad, porque baja de 6,05 al terminar la primera época a 5,97 en la segunda y a 5,94 en la tercera. Las dos últimas épocas, que consumen dos tercios del cómputo, aportan una mejora de 0,11 en la pérdida de validación.

Lo que muestra esa curva es un adaptador que satura. El modelo aprende deprisa lo que puede aprender con 4.512 pares y después deja de aprender, y no porque empiece a sobreajustar (la pérdida de validación sigue bajando, aunque sea poco) sino porque agota la señal disponible en el corpus. La consecuencia práctica es que ampliar el número de épocas no era el camino: el techo no lo pone el presupuesto de entrenamiento sino el tamaño y la homogeneidad del corpus, que procede casi por completo de un único registro textual. Esta observación explica por qué la configuración B mejora de forma clara sobre la A pero se queda muy por debajo de la D, y es la razón de fondo por la que el trabajo futuro apunta primero a ampliar el corpus y solo después a escalar el modelo.

Queda por justificar una decisión que atraviesa todo el capítulo y que hasta aquí se ha dado por supuesta: el uso del código de lengua `quy_Latn`, correspondiente al quechua de Ayacucho, para representar al Inga dentro de NLLB-200. El Inga no figura entre las doscientas lenguas del modelo, de modo que hay que asignarle alguna etiqueta existente, y `quy_Latn` es la más

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera próxima tipológicamente entre las disponibles. La alternativa habría sido añadir un token de lengua nuevo y entrenar su embedding desde cero, lo que con 4.512 pares no ofrece garantías.

La elección tiene una consecuencia que el apartado 4.6.3 cuantifica y que conviene anticipar aquí. Al forzar la decodificación en `quy_Latn`, el modelo sin adaptar no produce Inga defectuoso: produce quechua de Ayacucho competente, con su ortografía y su morfología propias, en 98 de los 100 ejemplos evaluados. El código de lengua actúa como un ancla fuerte, y esa ancla apunta a la lengua equivocada. El ajuste fino LoRA es precisamente lo que reorienta esa ancla hacia el Inga, y la Tabla 12 muestra que lo consigue: la configuración B ancla 98 de sus 100 salidas al vocabulario Inga del entrenamiento. Visto así, el valor del adaptador no está tanto en la mejora de BLEU, que es modesta, como en el cambio de lengua de salida, un efecto que ninguna de las tres métricas del capítulo sabe registrar.

4.5. PIPELINE LLM + RAG CON CLAUDE

Contribución de Daniel Eslava.

El segundo eje experimental opera sobre el modelo de lenguaje de frontera **Claude** de Anthropic, enriquecido con el contexto recuperado del sistema RAG descrito en la sección 4.3. La evaluación experimental se ejecutó con dos versiones del modelo (Sonnet 4.6 y Opus 4.7) para caracterizar el efecto del escalado del modelo subyacente sobre la calidad de traducción en condiciones de bajos recursos. El diseño del prompt es estructurado y específico por dirección. La dirección Inga-español utiliza un *system prompt* que sitúa al modelo como traductor especializado en una variante quechua del Putumayo y le pide responder únicamente con la traducción, sin explicaciones. La dirección español-Inga emplea un *system prompt* que enfatiza la primacía del vocabulario y los patrones gramaticales suministrados por el RAG sobre el conocimiento previo del modelo, dado el escaso volumen de Inga en los datos de preentrenamiento de cualquier modelo de lenguaje de frontera.

El cuerpo del prompt sigue un patrón consistente. La primera sección inyecta las cinco entradas léxicas más cercanas semánticamente a la oración a traducir, formateadas como lema (categoría): glosa. La segunda sección incluye hasta tres bloques de notas gramaticales del índice gramatical, truncados a 400 caracteres cada uno para no saturar el

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera contexto. La tercera sección entrega cinco ejemplos paralelos similares en formato INGA: ... / ESPAÑOL: ..., invertido para la dirección opuesta. El prompt cierra con la instrucción explícita y la oración objetivo.

La inspección cualitativa de las traducciones producidas confirma que la inyección del contexto recuperado modifica sustancialmente el comportamiento del modelo. Un ejemplo ilustrativo proviene del versículo Lucas 9:17, donde el texto Inga "Tukuikunami sagsagta mikurkakuna. Nispaka, chungá iskai saparu junda piti pitikuna tandachirkakuna." debe traducirse como "Y comieron todos, y se hartaron; y alzaron lo que les sobró, doce cestos de pedazos". La traducción del adaptador LoRA produce "Y comieron todos los que quedaron, y se llenaron los pedazos, doce mil pedazos", incurriendo en una confusión numérica grave (doce mil en lugar de doce). El pipeline con Claude más RAG, por contraste, produce "Y comieron todos, y se hartaron; y alzaron lo que sobró de los pedazos, doce cestas llenas", una traducción casi literalmente equivalente al gold de referencia. Este patrón se repite en la mayoría de los ejemplos donde el RAG logra recuperar versículos paralelos cercanos del corpus de entrenamiento, situación que confirma el aporte del paradigma de aumentación por recuperación al rendimiento del modelo de frontera en este escenario de bajos recursos.

4.5.1. Diseño de los prompts por dirección

El pipeline con Claude no usa un prompt único. La dirección de traducción cambia la dificultad del problema, y el prompt se adapta a esa asimetría. Para Inga-español el modelo traduce hacia una lengua que domina, de modo que el prompt prioriza la fidelidad al sentido y la naturalidad del español, y los ejemplos recuperados sirven sobre todo para desambiguar términos. Para español-Inga el reto es el inverso: el modelo debe generar una lengua que apenas vio en preentrenamiento, y el prompt enfatiza que la salida debe ajustarse a la variante del Putumayo y seguir de cerca la morfología de los ejemplos recuperados. Esta separación no es cosmética; la subsección cualitativa mostró que, sin esa presión explícita hacia el Inga, el modelo deriva con facilidad hacia el kichwa ecuatoriano.

El cuerpo del prompt sigue un patrón estable. Se fija primero el rol y la tarea, luego se inserta el bloque de ejemplos recuperados con su traducción de referencia, después las entradas relevantes del diccionario y de la gramática cuando el retriever las aporta, y al final la oración

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera a traducir. El orden importa: situar los ejemplos antes de la instrucción final ayuda al modelo a inferir el registro y la grafía esperados sin que haya que enunciarlos como reglas.

4.5.2. Recuperación multi-índice

El retriever consulta cuatro índices contruidos sobre LanceDB con embeddings gemini-embedding-001: uno léxico sobre las entradas del diccionario, uno gramatical sobre fragmentos de la gramática pedagógica, y dos de ejemplos paralelos, uno indexado por el lado Inga y otro por el lado español. La consulta se lanza contra el índice que corresponde al idioma de entrada, de modo que en Inga-español se busca por el texto Inga y en español-Inga por el texto español. Los resultados de los cuatro índices se combinan en un único bloque de contexto, con un tope por tipo de fuente para que los ejemplos no desplacen por completo a las entradas de diccionario y gramática.

La elección de mantener índices separados, en lugar de uno solo mezclado, responde a que cada fuente cumple una función distinta en el prompt. El diccionario resuelve piezas léxicas concretas; la gramática aporta patrones morfológicos; los ejemplos paralelos dan plantillas completas de oración. Mezclarlos en un único espacio de búsqueda diluiría esa división de trabajo y haría más difícil controlar cuánto pesa cada tipo de conocimiento en el contexto final.

4.5.3. Presupuesto de contexto del prompt

El contexto que se inyecta en cada llamada está acotado de forma deliberada y ese límite tiene consecuencias. Por cada oración a traducir, el módulo `claude_rag.py` compone un prompt de usuario con tres secciones: las cinco entradas léxicas más cercanas, en formato lema (categoría): glosa; los tres fragmentos gramaticales más cercanos, cada uno truncado a 400 caracteres; y los cinco ejemplos paralelos más cercanos, ordenados según la dirección de traducción. La respuesta se limita a 256 tokens.

El truncamiento de los fragmentos gramaticales a 400 caracteres es la decisión más discutible del diseño. Se tomó para acotar el coste por llamada y mantener el prompt en un tamaño predecible, pero corta pasajes de Levinsohn a mitad de explicación. En la consulta de sondeo sobre imasa que se describe en el apartado 4.3.1 se ve el efecto: el fragmento recuperado

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera introduce la regla y se interrumpe antes de los ejemplos que la ilustran. Un modelo de frontera puede completar la regla por analogía con el quechua sureño, y eso es exactamente lo que no se quiere, porque el objetivo es que produzca Inga y no una lengua emparentada. La alternativa habría sido segmentar la gramática en unidades semánticamente completas en lugar de trocear por longitud, y queda anotada como mejora del índice gramatical.

La dirección de traducción determina de qué índice se recuperan los ejemplos. Para inga2es se consulta el índice ejemplos, construido sobre el texto Inga; para es2ingá se consulta ejemplos_es, construido sobre el texto español. La consulta se hace siempre en la lengua de origen, de modo que la búsqueda semántica opere sobre embeddings de la misma lengua que la oración de entrada. Los dos índices contienen los mismos 4.512 pares del conjunto de entrenamiento y se diferencian solo en el campo que se vectoriza.

Conviene precisar un punto que el resumen del trabajo podía dejar ambiguo. Los índices de ejemplos suman 9.024 registros entre los dos, pero corresponden a 4.512 pares distintos indexados por sus dos caras. El número de ejemplos paralelos únicos disponibles para la recuperación es 4.512, no 9.024.

4.6. EVALUACIÓN COMPARATIVA

La evaluación se ejecutó sobre cien ejemplos del conjunto de validación, seleccionados con semilla 42 para que la muestra fuera reproducible y comparable entre configuraciones. El tamaño responde a un compromiso: es suficiente para que las diferencias entre configuraciones sean legibles en BLEU y chrF++, y a la vez acotado para mantener bajo control el costo de las llamadas al modelo de frontera, que se multiplican por cinco configuraciones y dos direcciones. Todas las configuraciones se midieron sobre exactamente el mismo subconjunto, condición necesaria para que la comparación intra-Claude de la Tabla 10 tenga sentido.

Se reportan tres métricas complementarias por una razón deliberada. BLEU captura el solape de n-gramas de palabras y es sensible a la repetición y a los errores de orden; chrF++ opera a nivel de caracteres y es más robusto para una lengua aglutinante como el Inga, donde la morfología carga buena parte de la información en sufijos; BERTScore mide cercanía en un

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera espacio de representaciones contextuales y sirve de contrapeso cuando las dos anteriores penalizan paráfrasis correctas. Ninguna es suficiente por sí sola, y la subsección cualitativa existe precisamente porque las tres juntas siguen sin capturar el fenómeno de la lengua incorrecta.

La evaluación comparativa se ejecutó sobre 100 ejemplos del *split* de validación seleccionados con semilla 42 para garantizar la reproducibilidad. La cantidad acotada responde a dos limitaciones operativas: el coste de las llamadas a la API de Anthropic asociadas al pipeline LLM con recuperación aumentada y el tiempo de evaluación local del modelo NLLB con generación por *beam search* de cuatro caminos. Los 564 ejemplos del *val set* completo y los 565 ejemplos del *test set* quedan disponibles para extensiones posteriores del trabajo, incluida la validación humana con hablantes nativos.

Las cinco configuraciones de la Tabla 4 del Capítulo 3 se evaluaron en las dos direcciones de traducción, totalizando diez corridas. Las métricas empleadas son BLEU corpus-level (sacrebleu), chrF++ con word_order=2 (sacrebleu) y BERTScore F1 con el modelo XLM-RoBERTa multilingüe, configuradas de forma idéntica a las recomendaciones recientes de AmericasNLP (Ebrahimi et al., 2024; de Gibert et al., 2025). El pipeline LLM más RAG se ejecutó con Claude **Opus 4.7** como modelo principal de reporte. Los resultados consolidados se presentan en la Tabla 9.

Tabla 9
Métricas BLEU, chrF++ y BERTScore por configuración y dirección sobre 100 ejemplos del val set

Config	Direccion	BLEU	chrF++	BERTScore F1
A: NLLB-200 zero-shot (quy_Latn)	Inga -> Espanol	1,82	19,50	0,695
A: NLLB-200 zero-shot (quy_Latn)	Espanol -> Inga	0,16	15,88	0,674

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

B: NLLB-200 + LoRA bidireccional	Inga -> Espanol	8,18	27,19	0,752
B: NLLB-200 + LoRA bidireccional	Espanol -> Inga	1,79	22,89	0,676
C: Claude Opus 4.7 zero-shot	Inga -> Espanol	4,37	29,45	0,736
C: Claude Opus 4.7 zero-shot	Espanol -> Inga	0,32	21,75	0,722
D: Claude Opus 4.7 + RAG multi- indice	Inga -> Español	17,89	43,28	0,790
D: Claude Opus 4.7 + RAG multi- indice	Español -> Inga	10,95	38,19	0,788
E: LoRA + Claude Opus 4.7 + RAG (refinamiento)	Inga -> Español	10,88	37,55	0,770
E: LoRA + Claude Opus 4.7 + RAG (refinamiento)	Español -> Inga	9,98	39,00	0,790

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

Nota. Elaboración propia a partir de los Notebooks 10 y 11. Las cifras en negrita corresponden a la configuración con el valor más alto por métrica y dirección. El pipeline LLM se ejecutó con Claude Opus 4.7 como modelo principal de reporte; la corrida paralela con Claude Sonnet 4.6 sobre el mismo conjunto de validación se consigna en el Anexo A.

La comparación entre los dos modelos de Claude evaluados sobre exactamente el mismo subconjunto del *val set* permite cuantificar el efecto del escalado del modelo subyacente. Los resultados se sintetizan en la Tabla 10.

Tabla 10

Comparación intra-Claude (Sonnet 4.6 frente a Opus 4.7) sobre el mismo conjunto de validación, métricas BLEU

Configuración	Dirección	Sonnet 4.6	Opus 4.7	Δ Opus–Sonnet
C: Claude zero-shot	Inga → Español	5,17	4,37	−0,80
C: Claude zero-shot	Español → Inga	0,27	0,32	+0,05
D: Claude + RAG	Inga → Español	11,97	17,89	+5,92
D: Claude + RAG	Español → Inga	8,22	10,95	+2,73
E: LoRA + Claude + RAG (refinamiento)	Inga → Español	12,01	10,88	−1,13
E: LoRA + Claude + RAG (refinamiento)	Español → Inga	8,82	9,98	+1,16

Nota. Elaboración propia. Diferencias positivas a favor de Opus 4.7 en negrita.

El patrón es revelador: el modelo de mayor capacidad obtiene su ventaja principal cuando dispone de contexto recuperado relevante (configuración D), donde alcanza una mejora cercana a 6 puntos BLEU en la dirección Inga-español. En ausencia de contexto (configuración C) los dos modelos rinden prácticamente igual; cuando el *seed* del LoRA introduce errores

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera léxicos (configuración E), el modelo menos avanzado preserva el *seed* con mayor fidelidad y obtiene un BLEU ligeramente superior. La observación complementa el análisis que se desarrolla en el Capítulo 5.

Cinco hallazgos se derivan de esta tabla.

1. Primero, la configuración D (Claude Opus 4.7 con recuperación aumentada multi-índice) obtiene el mejor desempeño en las dos direcciones de traducción y en las tres métricas reportadas. En la dirección Inga-español alcanza 17,89 puntos BLEU, 43,28 puntos chrF++ y 0,790 de BERTScore F1, cifras que sitúan al sistema en el lado alto del rango reportado por la literatura reciente para variantes quechuas con corpus comparables (Chen et al., 2024; Garcia Gilabert et al., 2024).
2. Segundo, la recuperación aumentada actúa como factor multiplicador de la calidad del modelo de frontera. El paso de la configuración C (Opus 4.7 sin RAG) a la configuración D mejora el BLEU de 4,37 a 17,89 en Inga-español, una ganancia de 13,5 puntos absolutos, y de 0,32 a 10,95 en español-Inga, una ganancia de 10,6 puntos. Este resultado confirma empíricamente la premisa del paradigma RAG-MT introducido por Wang et al. (2024) en el escenario específico de una lengua de recursos extremadamente bajos.
3. Tercero, el ajuste fino del modelo multilingüe (configuración B) ofrece una mejora sólida sobre el modelo zero-shot (configuración A) en la dirección Inga-español, donde el BLEU pasa de 1,82 a 8,18, un factor de 4,5x. La mejora en la dirección español-Inga es de mucha menor magnitud, de 0,16 a 1,79, debido al modo de fallo de repetición patológica descrito en la sección 4.4. La asimetría confirma que la generación de la lengua con datos escasos es estructuralmente más difícil que el reconocimiento de la lengua en el extremo fuente.
4. Cuarto, la configuración E (refinamiento de la salida del LoRA por Claude Opus 4.7 con RAG) no supera a la configuración D directa. En Inga-español, E obtiene 10,88 BLEU frente a los 17,89 de D, una pérdida de 7,0 puntos. En español-Inga las dos configuraciones quedan próximas (9,98 frente a 10,95). El resultado sugiere que la salida del adaptador LoRA, cuando se ofrece como semilla al modelo de frontera,

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera induce un sesgo hacia traducciones menos fieles que la referencia, posiblemente porque el modelo de frontera tiende a respetar la estructura del *seed* en lugar de reescribir desde cero. La inspección manual de varios ejemplos muestra que Opus 4.7 hereda errores léxicos del LoRA y propaga ajustes solo en el plano sintáctico, lo que penaliza las métricas basadas en *n-grama*.

- Quinto, BERTScore presenta menor variación entre configuraciones que BLEU y chrF++, lo cual es esperable dado que opera sobre representaciones contextuales que toleran reformulaciones semánticamente equivalentes. El rango de BERTScore F1 abarca de 0,674 (configuración A en español-Inga) a 0,790 (configuración D en Inga-español y configuración E en español-Inga). Esta compresión sugiere que las configuraciones evaluadas, incluso aquellas con BLEU muy bajo, producen salidas semánticamente parcialmente relacionadas con la referencia y que la diferencia perceptual entre ellas se concentra en la corrección léxica y morfológica capturada por las métricas basadas en superficie.

La comparación visual de las tres métricas por configuración y dirección se presenta en la Figura 11.




Figura 11

Comparativa de BLEU, chrF++ y BERTScore por configuración y dirección

Nota. Elaboración propia a partir del Notebook 11. Cada panel corresponde a una métrica; las barras azules indican la dirección Inga-español y las rojas la dirección español-Inga. La configuración D destaca consistentemente en los tres paneles.

4.6.1. Protocolo de evaluación y validez de las métricas

Las tres métricas se calculan con el módulo `src/eval/metrics.py`, que envuelve implementaciones estándar: BLEU a nivel de corpus con `sacrebleu`, `chrF++` con `sacrebleu` y `word_order` igual a 2, y BERTScore F1 sobre XLM-RoBERTa multilingüe sin reescalado de línea base. Fijar estas decisiones por escrito importa más de lo que parece, porque BLEU admite variantes de tokenización y de suavizado que cambian el resultado varios puntos y hacen incomparables cifras que se presentan como equivalentes.

Hay una limitación en la configuración de BERTScore que debe declararse porque afecta a la lectura de la Tabla 9. El scorer se instancia con `lang` igual a `es` para las dos direcciones de traducción. En la dirección Inga-español esto es correcto, porque la referencia está en español. En la dirección español-Inga no lo es: la referencia está en Inga, una lengua que XLM-RoBERTa no vio durante su preentrenamiento, y el modelo la procesa como si fuera español. El resultado es que en esa dirección BERTScore no mide adecuación semántica sino, más bien, plausibilidad de las subunidades ortográficas, y por eso sus valores se comprimen en un rango estrecho y varían poco entre configuraciones. La lectura correcta es que BERTScore aporta información útil en Inga-español y debe tomarse con reservas en español-Inga, dirección en la que `chrF++`, que opera sobre caracteres y no depende de ningún modelo preentrenado, es la métrica más fiable de las tres. Ninguna conclusión del trabajo se sostiene únicamente sobre el BERTScore de la dirección español-Inga.

La muestra de evaluación son 100 ejemplos extraídos del conjunto de validación con `random_state` igual a 42. Su composición no es homogénea: 99 versículos del Nuevo Testamento y un único artículo de la Constitución, el artículo 10. Esa proporción refleja la del corpus, pero implica que las cifras de la Tabla 9 describen el rendimiento del sistema sobre registro bíblico y no autorizan a extrapolarlo al registro jurídico ni al conversacional. El único ejemplo constitucional de la muestra se comenta por separado en el apartado 4.6.2 justamente porque es el único.

Las configuraciones A y B se generan localmente con búsqueda en haz de cuatro caminos y un máximo de 128 tokens nuevos; las configuraciones C, D y E se generan por API con un máximo

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera de 256 tokens. Las diez corridas comparten los mismos 100 ejemplos, condición necesaria para que las diferencias entre columnas sean atribuibles a la configuración y no a la muestra.

Queda por decir lo que el protocolo no cubre. No se midió sobre el conjunto de prueba, que permanece intacto con sus 565 ejemplos: todas las cifras de este capítulo son de validación, lo que en rigor las convierte en estimaciones de desarrollo y no en una evaluación final independiente. Tampoco se calcularon intervalos de confianza ni pruebas de significancia por remuestreo, de modo que las diferencias pequeñas entre configuraciones, y en particular la distancia de 1,13 puntos BLEU entre D y E en la dirección español-Inga, no pueden declararse estadísticamente significativas. Las diferencias grandes, como los 13,5 puntos que separan a C de D, son de una magnitud que ningún intervalo razonable haría desaparecer.

4.6.2. Análisis cualitativo de las traducciones

Las métricas automáticas de la Tabla 9 ordenan las configuraciones, pero no explican por qué una gana. BLEU y chrF++ miden solape de n-gramas frente a una referencia única, y BERTScore mide cercanía semántica en un espacio contextual; ninguna de las tres dice si el sistema generó Inga o si, por el contrario, devolvió una lengua emparentada pero distinta. Para responder esa clase de preguntas se inspeccionaron manualmente las predicciones de las cinco configuraciones sobre una muestra del conjunto de validación, guardadas en `datos/predicciones_val_completo.jsonl`. De esa inspección salen cuatro patrones que conviene documentar, porque cada uno matiza la lectura de las cifras.

Degeneración del modelo multilingüe sin adaptar. La configuración A (NLLB-200-distilled-600M en zero-shot) cae con frecuencia en bucles de repetición cuando la oración de entrada es larga. En Tito 2:3, una entrada Inga de varias cláusulas, la salida en español repite "a todas las que no hablan" más de diez veces hasta agotar la ventana de decodificación. El fenómeno es conocido en decodificación neuronal y se agrava cuando el modelo no reconoce bien el idioma de origen: al no tener un punto de anclaje semántico, el decodificador se queda atrapado en el token de mayor probabilidad local. Es el tipo de error que BLEU penaliza con dureza, y explica buena parte de la distancia entre la configuración A y el resto en oraciones largas. En oraciones cortas, en cambio, el mismo modelo se comporta de forma aceptable, como se verá enseguida.

El problema de la lengua incorrecta en la dirección español-Inga. Este es el hallazgo cualitativo más relevante del trabajo, y no se aprecia bien solo con las métricas. Cuando se pide traducir del español al Inga, los sistemas que carecen de anclaje al Inga del Putumayo no devuelven una traducción mala: devuelven una traducción a otra lengua quechua. La Tabla 11 lo ilustra con Juan 4:32. La configuración A produce "Jesustaq paykunata nirqan: Qankuna mana reqsiq kanaykichispaq mikhuq kani, nispa", que es quechua sureño: las marcas -qa y -taq, el sufijo -nispa y las consonantes glotalizadas de mikhuq delatan la variante de mayor presencia en los datos de preentrenamiento de NLLB. La configuración C, el mismo Opus 4.7 pero sin contexto recuperado, produce "Y pai nirka: Nuka charini mikui mikungapa, mana kankuna yachankichi", una forma híbrida que ya se acerca al Inga en el léxico pero conserva la grafía con y de yachankichi, ajena al corpus. Solo con la recuperación aumentada, en la configuración D, la salida se ancla del todo: "Paika nirkakunata: Nukaka kankuna mana iachaska sug mikuita charini mikungapa", con la grafía iachaska en lugar de yachaska y la morfología que aparece en el corpus paralelo. El contexto recuperado no solo mejora el contenido: reorienta la salida hacia la variante correcta de una familia lingüística con docenas de variantes mutuamente ininteligibles.

El mismo efecto aparece en el artículo 10 de la Constitución, "El castellano es el idioma oficial de Colombia". La configuración A devuelve "Kastillanuqa Colombia suyupi rimaymi", de nuevo quechua sureño (suyu por territorio, el enclítico -qa). Las configuraciones con recuperación producen en cambio formas ancladas al material Inga indexado: Opus 4.7 devuelve "Lanku simi rimaimi ká Kulumbia Llagtapa idioma" y Sonnet 4.6 "Kastilla simi kami Kulumbia llagtapi kawsag tukui runakunapata rimai", ambas con llagta y la grafía Kulumbia propias del corpus, aunque la primera recurre al préstamo idioma en lugar de traducirlo. Que el ejemplo provenga del corpus jurídico, y no del Nuevo Testamento, sugiere que el anclaje por recuperación funciona también fuera del dominio bíblico que domina el corpus.

Conviene advertir, no obstante, que este ejemplo concreto arrastra un problema de la propia referencia. El texto Inga emparejado con el artículo 10 en el corpus no traduce la frase sobre el castellano, sino la que reconoce las lenguas de los pueblos indígenas, y varias configuraciones interpretaron la raíz iura como árbol y produjeron traducciones sobre el

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera idioma de los árboles. El caso ilustra a la vez un límite del sistema y un límite del corpus; esto último se retoma en el apartado 4.6.5.

El aporte concreto de la recuperación. Más allá de la elección de variante, el contexto recuperado aporta terminología y resuelve ambigüedades léxicas. En las inspecciones se observa que los ejemplos recuperados del índice paralelo actúan como plantillas morfológicas: cuando el retriever encuentra un versículo de estructura parecida, Claude reutiliza sus terminaciones verbales y sus posposiciones. Esto encaja con lo que reportan Enis y Hopkins (2024) sobre el uso de Claude para traducción de bajos recursos mediante ejemplos en el prompt, y con la propuesta general de recuperación aumentada de Lewis et al. (2020): el conocimiento no está en los pesos del modelo sino en lo que se le pasa en tiempo de inferencia.

Lo que todavía falla en la mejor configuración. Conviene no sobrevender la configuración D. En la dirección Inga-español sigue cometiendo errores de referencia (confunde sujetos en oraciones con varias cláusulas subordinadas) y, en español-Inga, alterna grafías dentro de una misma oración cuando los ejemplos recuperados no son homogéneos. El caso de la Constitución muestra otra grieta: la palabra Inga de origen se interpretó como derivada de "iura" (árbol, planta) y varias configuraciones tradujeron "idioma de los árboles", lo que apunta tanto a un límite del sistema como a la heterogeneidad de la propia traducción Inga de referencia. Estos residuos marcan el techo actual y alimentan las líneas de trabajo futuro del capítulo 5.

La inspección caso a caso se puede respaldar con una medida agregada que no depende del criterio del lector: la longitud de las salidas. La referencia Inga del conjunto de evaluación tiene 21,3 palabras de media y la referencia española 20,3. En la dirección español-Inga, las configuraciones con recuperación se mantienen cerca de ese orden de magnitud, con 16,5 palabras la D y 17,6 la E, mientras que la configuración B se dispara hasta 27,3 palabras. Ese exceso no es riqueza expresiva: es el bucle de repetición que se cuantifica en el apartado siguiente, inflando artificialmente el recuento. La configuración A, en el extremo opuesto, se queda en 14,5 palabras, por debajo de la referencia, lo que encaja con salidas cortas en una lengua que el modelo domina mal.

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

En la dirección Inga-español el patrón se invierte. Todas las configuraciones producen salidas más largas que la referencia, entre 24,3 y 33,4 palabras frente a las 20,3 del gold. Aquí la explicación no es la degeneración sino la naturaleza del texto fuente: los versículos de la Reina-Valera de 1909 son sintácticamente comprimidos y arcaizantes, y tanto NLLB como Claude tienden a desplegarlos en castellano contemporáneo, más explícito y más largo. Es un sesgo de estilo que las métricas de n-gramas penalizan aunque la traducción sea correcta, y conviene tenerlo presente al comparar las cifras de esta dirección con las de la literatura, donde las referencias rara vez son bíblicas.

Tabla 11

Ejemplos de traducción por configuración y dirección sobre el conjunto de validación

Referencia	Texto fuente (español)	A (NLLB zero-shot)	D con Opus 4.7	D con Sonnet 4.6
Juan 4:32	Yo tengo una comida que comer, que vosotros no sabéis.	Jesustaq paykunata nirqan: Qankuna mana reqsiq kanaykichispaq mikhuq kani, nispa. (quechua sureño)	Paika nirkakunata: Nukaka kankuna mana iachaska sug mikuika charini mikungapa. (Inga)	Paika painakunata nirka: Nukaka mikungapa mikuika tian, kamkunaka mana yachangichu. (Inga con grafía y)
Lucas 24:38	Mas él les dice: ¿Por qué estáis turbados, y suben pensamientos	Jesustaq paykunata nirqan: ¿Imanasqataq llakikunkichis? ¿Imanasqataq sonqoykichispi	Pai nirkakunata: ¿Imapatak chasa manchaspa kangichi, i imapatak chasa	Paika nirkakunata: ¿Imapatak manchanakungichi, iuiaikunatak sungullapi

	á vuestros corazones?	yuyashankichis? (quechua sureño)	sungullapi iuianakungichi? (Inga)	wicharimungichi? (Inga)
Constitución art. 10	El castellano es el idioma oficial de Colombia.	Kastillanuqa Colombia suyupi rimaymi. (quechua sureño)	Lanku simi rimaimi ká Kulumbia Llagtapa idioma. (Inga)	Kastilla simi kami Kulumbia llagtapi kawsag tukui runakunapata rimai. (Inga)

Nota. Elaboración propia a partir de los Notebooks 10 y 11. Los tres ejemplos corresponden a la dirección español-Inga, que es donde se juega la cuestión de la variante. Las salidas se transcriben literalmente; los guiones de diálogo se normalizaron. La configuración A es idéntica en ambas corridas porque no interviene el modelo de lenguaje de frontera. La variante detectada se indica entre paréntesis. En Juan 4:32, la salida de Sonnet contiene la letra y (yachangichu), grafema ausente del Inga del corpus.

4.6.3. Taxonomía de errores

El análisis cualitativo se apoya en casos concretos. Para respaldarlo con una mirada de conjunto, las salidas de las cinco configuraciones sobre los 100 ejemplos de la muestra se clasificaron por tipo de fallo mediante criterios automáticos y deterministas, implementados en el módulo `src/eval/error_analysis.py`. La tabla que sigue puede regenerarse desde el fichero de predicciones sin intervención manual, que es la condición para que un recuento de errores sea algo más que una impresión. Los criterios se enuncian antes de mostrar los resultados, porque de ellos depende cómo han de leerse.

Una salida se marca como degenerada cuando contiene un n-grama de hasta cuatro palabras repetido tres o más veces de forma consecutiva. Se marca como desbordada cuando supera en más de dos veces y media la longitud de la referencia. Y para la dirección español-Inga, que es donde se juega la cuestión de la variante, se emplean dos indicadores ortográficos y léxicos en lugar de un juicio subjetivo sobre a qué lengua se parece la salida.

El primero aprovecha un rasgo de la escritura del Inga del Putumayo que resulta inusualmente discriminante. Sobre los 823.744 caracteres de texto Inga del conjunto de entrenamiento, la letra y no aparece ni una sola vez y la letra q aparece seis veces, un 0,001 por ciento. El Inga

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

escribe iui ai donde el quechua sureño escribe yuyay, y kan donde aquel escribe qan. Ambos grafemas, en cambio, son centrales en la ortografía del quechua sureño y del kichwa ecuatoriano. La presencia de una q o una y en una salida es por tanto evidencia objetiva de que el sistema no está escribiendo en la variante del corpus. El segundo indicador mide la fracción de palabras de la salida que pertenecen al vocabulario Inga del entrenamiento, formado por 13.575 tipos, y considera la salida anclada al Inga cuando esa fracción alcanza la mitad.

Los resultados de la Tabla 12 son más nítidos de lo que las métricas agregadas dejaban entrever. El modelo multilingüe sin adaptar (configuración A) produce grafías ajenas al Inga en 98 de los 100 ejemplos y solo una de sus salidas alcanza el umbral de anclaje léxico. No está traduciendo mal al Inga: no está traduciendo al Inga en absoluto, sino al quechua que conoce, que es el sureño del par quy_Latn con el que se le fuerza a decodificar. Ninguna métrica de la Tabla 9 dice esto, y sin embargo es lo primero que habría que saber del sistema.

El ajuste fino corrige el idioma y rompe el decodificador. La configuración B invierte por completo los dos indicadores, con 98 salidas ancladas al vocabulario Inga y solo una con grafía ajena, lo que confirma que 4.512 pares bastan para enseñarle a NLLB en qué lengua debe escribir. Pero al mismo tiempo degenera en 51 de los 100 ejemplos, más de la mitad, y esa es la explicación completa de por qué su BLEU en español-Inga se queda en 1,79 pese a haber aprendido la variante correcta. El adaptador aprende el léxico y pierde la capacidad de detenerse.

La recuperación aumentada consigue las dos cosas a la vez. La configuración D reduce la grafía ajena a 5 ejemplos, ancla 98 salidas al vocabulario Inga y no degenera en ninguno, mientras que la configuración C, el mismo modelo sin contexto recuperado, se queda a medio camino con 60 salidas de grafía ajena y solo 38 ancladas. La diferencia entre C y D no está en el modelo, que es el mismo, sino únicamente en lo que se le entrega en el prompt. Es la evidencia más directa de que, para este par de lenguas, el conocimiento que hace falta no está en los pesos sino en el contexto.

Un cuarto tipo de error no admite recuento automático y aparece con regularidad en la inspección: los fallos de referencia y concordancia. En oraciones con varias cláusulas

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera subordinadas, incluso la configuración D confunde a veces quién hace qué, o desplaza un sujeto de una cláusula a otra. Son errores sutiles, que no degradan la fluidez de la salida y que por eso pueden pasar inadvertidos a una métrica de superficie, pero que alteran el sentido. Su persistencia en la mejor configuración marca uno de los límites actuales del sistema.

Conviene cerrar con un dato en positivo: ninguna de las cinco configuraciones produjo salidas vacías o truncadas. Todas devuelven siempre una traducción completa, aunque sea defectuosa. El problema, cuando lo hay, no es de cobertura sino de calidad o de variante.

Tabla 12

Recuento de errores por tipo y configuración sobre los 100 ejemplos del conjunto de validación

Indicador	Dirección	A	B	C	D	E
Degeneración por repetición	Inga-es	6	8	1	1	1
Degeneración por repetición	es-Inga	6	51	0	0	0
Desbordamiento de longitud (>2,5x ref)	Inga-es	17	7	13	12	13
Grafía ajena al Inga (letras q o y)	es-Inga	98	1	60	5	6
Salida anclada al vocabulario Inga	es-Inga	1	98	38	98	97
Salidas vacías o truncadas	ambas	0	0	0	0	0

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

Nota. Elaboración propia a partir de datos/predicciones_val_completo.jsonl mediante el módulo src/eval/error_analysis.py, sobre la corrida principal con Claude Opus 4.7. Todos los indicadores son deterministas y reproducibles; los criterios se definen en el texto. Las filas de grafía y anclaje no son excluyentes entre sí.

4.6.4. Comparación intra-Claude: por qué el modelo mayor aprovecha mejor el contexto

La Tabla 10 registra que Opus 4.7 aventaja a Sonnet 4.6 en 5,92 puntos BLEU en la configuración D, pero no explica de dónde sale esa ventaja. Los indicadores del apartado anterior, aplicados a las dos corridas por separado, permiten responderlo.

En la configuración C, sin contexto recuperado, los dos modelos se comportan prácticamente igual, y ambos mal: Sonnet produce grafía ajena al Inga en 83 de los 100 ejemplos y Opus en 60, con anclajes léxicos de 5 y 38 respectivamente. Ninguno de los dos sabe escribir Inga por su cuenta, lo que era esperable. La diferencia aparece cuando se les entrega el mismo contexto recuperado. En la configuración D, Opus deja solo 5 salidas con grafía ajena, frente a las 19 de Sonnet. Es decir, ante ejemplos y vocabulario idénticos, el modelo de mayor capacidad se adhiere con más rigor a la ortografía y al léxico que se le muestran, mientras que el menor se desliza con más frecuencia hacia la variante quechua que ya traía aprendida.

La ventaja de Opus, por tanto, no es una mayor competencia previa en Inga, lengua que ninguno de los dos conoce, sino una mayor fidelidad al contexto que se le entrega. Es un matiz con consecuencias prácticas: en un sistema RAG sobre una lengua de recursos escasos, lo que diferencia a los modelos no es tanto lo que saben como cuánto se dejan corregir por lo que se les muestra. Explica además la anomalía de la configuración E, donde Sonnet obtiene mejor BLEU en la dirección Inga-español: cuando el contexto incluye una semilla defectuosa producida por el LoRA, la mayor docilidad de Opus hacia el contexto deja de ser una virtud, porque lo que respeta con fidelidad es un error.

La Tabla 11 del apartado anterior permite inspeccionar esa diferencia directamente: recoge tres ejemplos de la muestra con las salidas de ambos modelos junto a las del modelo multilingüe sin adaptar.

4.6.5. Amenazas a la validez de la evaluación

Cuatro factores acotan hasta dónde pueden llevarse las conclusiones de este capítulo.

El primero es el ruido de alineación del propio corpus, que contamina las referencias contra las que se mide. La alineación canónica versículo a versículo descrita en el apartado 4.2.3 supone que la numeración de la edición Inga de Wycliffe y la de la Reina-Valera de 1909 coinciden, y no siempre lo hacen. En la muestra de evaluación hay al menos un caso claro: en Juan 4:32, el texto español de referencia dice que hay una comida que comer que los discípulos no conocen, mientras que el texto Inga emparejado corresponde en realidad al contenido de Juan 3:32, sobre el testimonio de lo que se ha visto y oído. En ese ejemplo, cualquier sistema que traduzca correctamente el español será penalizado por las tres métricas, porque la referencia no es la traducción de la oración fuente. El efecto empuja todas las cifras hacia abajo por igual, de modo que no invalida la comparación entre configuraciones, que es el objeto del experimento, pero sí obliga a leer los valores absolutos de BLEU como un límite inferior del rendimiento real.

El segundo es el tamaño y la composición de la muestra. Cien ejemplos, de los cuales 99 son versículos bíblicos, no permiten estimar el rendimiento fuera del registro religioso ni calcular intervalos de confianza estrechos. El conjunto de prueba, con 565 ejemplos, sigue sin utilizarse.

El tercero es la referencia única. BLEU y chrF++ comparan contra una sola traducción válida, cuando en traducción existen muchas. Este problema afecta a toda la traducción automática, pero se agrava en lenguas sin norma ortográfica estabilizada, donde una misma palabra admite varias escrituras legítimas y el sistema es penalizado por elegir una distinta de la del corpus.

El cuarto es la ausencia de juicio humano. Ninguna de las salidas fue evaluada por hablantes de Inga. Los indicadores automáticos de variante que se introducen en el apartado 4.6.3 mitigan parcialmente esta carencia, porque detectan de forma objetiva cuándo el sistema escribe en otra lengua, pero no pueden pronunciarse sobre si una traducción anclada al léxico correcto es además aceptable, respetuosa con el registro y comprensible para un hablante. Esa validación queda como la pieza pendiente del trabajo y se recoge en las líneas futuras del Capítulo 5.

4.7. REPOSITORIO DE CÓDIGO Y DATOS

El código del proyecto se organiza ahora como un paquete Python reproducible bajo `pyproject.toml` con dependencias bloqueadas en `uv.lock`. El árbol del repositorio incluye doce notebooks (00 a 11) que cubren desde la configuración del entorno hasta la evaluación comparativa, un paquete `src/` con los módulos reutilizables del RAG (`embeddings`, `indexes`, `retriever`), del fine-tuning (`nllb_lora`), del pipeline LLM (`claude_rag`) y de la evaluación (`metrics`), y los corpus generados bajo `datos/` (`corpus_paralelo.jsonl`, las tres particiones, las predicciones por configuración, las métricas consolidadas). Los pesos del adaptador LoRA y los índices LanceDB están excluidos del control de versiones por su tamaño, pero se regeneran íntegramente al reejecutar los notebooks correspondientes sobre los recursos primarios. El detalle completo se encuentra en el Anexo A.

La reproducción completa del trabajo sigue el orden numérico de los notebooks y no requiere decisiones manuales. Los notebooks 00 a 07 reconstruyen el corpus desde las fuentes OCR y producen las particiones; el 08 levanta los cuatro índices vectoriales, único paso que consume la API de embeddings de Google; el 09 entrena el adaptador LoRA; y el 10 y el 11 ejecutan las diez corridas de evaluación, de las cuales las cinco del modelo de frontera consumen la API de Anthropic. Todos los pasos con componente aleatorio (la partición del corpus, el muestreo de los 100 ejemplos de evaluación y el barajado del entrenamiento) están fijados con semilla 42, de modo que una reejecución produce exactamente los mismos conjuntos.

Los dos artefactos que no se regeneran solos son los índices vectoriales y el adaptador, y ambos se versionan en el repositorio: el adaptador ocupa 9,4 megabytes y los índices 127 megabytes, tamaños que caben en un repositorio Git sin recurrir a almacenamiento externo.

Quien quiera reproducir únicamente la evaluación puede por tanto saltarse los notebooks 00 a 09 y ejecutar directamente el 10 y el 11 sobre los artefactos publicados, lo que reduce el coste de verificación a las llamadas a la API del modelo de frontera.

El módulo `src/eval/error_analysis.py`, introducido en el apartado 4.6.3, se ejecuta sin credenciales de ningún tipo, porque opera únicamente sobre el fichero de predicciones ya generado. Cualquier lector puede regenerar la Tabla 11 completa y verificar los criterios de degeneración y de variante lingüística sin coste alguno, que era precisamente el objetivo de convertir el recuento de errores en código.

5. CONCLUSIONES Y TRABAJO FUTURO

5.1. CONCLUSIONES

El trabajo demuestra la viabilidad técnica de construir un sistema bidireccional de traducción automática Inga-español a partir de fuentes primarias heterogéneas y mediante dos paradigmas complementarios. Cinco resultados concretos sustentan esta afirmación.

Primero, el corpus paralelo Inga-Español alcanzó 5.641 pares verificados, una cifra que excede el umbral de los 5.000 pares planteado como meta mínima del proyecto y que supera ampliamente las cifras reportadas por los antecedentes académicos directos para el par lingüístico (Prieto et al., 2024; Salazar et al., 2025). La fuente del 100% de estos pares es el Nuevo Testamento, alineado canónicamente entre la traducción Wycliffe en Inga y la traducción Reina-Valera 1909 en español. La elección de Reina-Valera 1909 sobre otras alternativas católicas como la Biblia Latinoamericana responde a una restricción de licenciamiento que se evaluó explícitamente: el compromiso del proyecto con la liberación abierta de recursos para la comunidad Inga es incompatible con la inclusión de texto bajo copyright vigente.

Segundo, el diseño del sistema de recuperación aumentada se materializó en cuatro índices vectoriales operativos sobre LanceDB con embeddings producidos por `gemini-embedding-001`. La validación cualitativa del retriever sobre tres queries representativas (una palabra suelta, una frase corta, una oración completa) confirma que el sistema recupera contexto

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera semánticamente relevante en los tres niveles de granularidad. La existencia del cuarto índice (`ejemplos_es`) habilita la dirección de traducción español a Inga sin necesidad de reentrenar embeddings.

Tercero, la adaptación de NLLB-200-distilled-600M mediante LoRA quedó implementada como pipeline reproducible con el corpus duplicado para entrenamiento bidireccional. Un único adaptador sirve para ambas direcciones según los códigos de lengua que se le pasen al tokenizador en inferencia, lo que reduce el costo de almacenamiento y mantenimiento respecto a entrenar dos adaptadores independientes.

Cuarto, el pipeline LLM más RAG con Claude Opus 4.7 opera con *prompts* estructurados específicos por dirección, donde el *prompt* para español-Inga enfatiza la primacía del vocabulario y la gramática recuperados sobre el conocimiento previo del modelo, dado que Claude tiene exposición limitada al Inga durante su preentrenamiento. El sistema produce traducciones léxicamente fieles a la referencia en la mayoría de los versículos del *val set* y recupera correctamente la dirección español-Inga, evitando los modos de fallo de repetición observados en el adaptador NLLB.

Quinto, la evaluación comparativa de las cinco configuraciones experimentales (A, B, C, D y E) en ambas direcciones se ejecutó sobre 100 ejemplos del conjunto de validación, con métricas BLEU, chrF++ y BERTScore consolidadas en la Tabla 9. La configuración D (Claude Opus 4.7 con recuperación aumentada multi-índice) obtiene el mejor desempeño en las dos direcciones y en las tres métricas: 17,89 BLEU y 0,790 BERTScore F1 en Inga-español; 10,95 BLEU y 0,788 BERTScore F1 en español-Inga. La ganancia respecto al modelo de frontera sin recuperación (configuración C) es de 13,5 puntos BLEU en Inga-español y 10,6 puntos en español-Inga, cifras que confirman empíricamente el aporte del paradigma RAG-MT al rendimiento de un modelo de frontera operando sobre una lengua de recursos extremadamente bajos.

El recorrido del trabajo permite afirmar que la barrera principal para la traducción automática del par Inga-español no es la arquitectura del modelo sino la disponibilidad de contexto en tiempo de inferencia. Las cinco configuraciones evaluadas comparten modelos base sólidos; lo que las separa es cuánto saben del Inga del Putumayo en el momento de traducir. Esa observación, que en el capítulo 4 aparece como un dato, aquí se eleva a conclusión: para una

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera
lengua con menos de seis mil pares paralelos, inyectar ejemplos recuperados rinde más que ajustar los pesos con esos mismos pares.

Una segunda conclusión, de orden metodológico, es que la evaluación exclusivamente automática resulta insuficiente para este par de lenguas. Como se mostró en la subsección cualitativa, un sistema puede obtener un BLEU bajo y aun así producir una salida gramatical, o puede generar una lengua quechua distinta del Inga sin que la métrica lo distinga con claridad. Cualquier trabajo posterior sobre el Inga debería combinar métricas de n-gramas con revisión por hablantes, aunque sea sobre muestras pequeñas.

5.2. DISCUSIÓN

Cuatro observaciones se derivan del cruce entre los hallazgos cuantitativos del Capítulo 4 y la literatura reciente sobre traducción de lenguas de bajos recursos.

La primera observación concierne al efecto del ajuste fino del modelo multilingüe respecto al modelo de frontera. La configuración B (NLLB-200 con LoRA bidireccional) mejora sustancialmente sobre el modelo base zero-shot (configuración A) en la dirección Inga-español, donde el BLEU asciende de 1,82 a 8,18. Sin embargo, la configuración D supera a B por un factor cercano a 2,2 en BLEU (17,89 frente a 8,18) y a 1,6 en chrF++ (43,28 frente a 27,19). Esta diferencia muestra que, en el régimen de datos paralelos extremadamente escasos del Inga, un modelo de frontera con acceso a contexto recuperado supera al ajuste fino de un modelo dedicado de menor tamaño. El resultado complementa lo observado por Enis y Hopkins (2024) sobre la *eficiencia de recursos* de Claude en pares de bajos recursos, y se alinea con la evidencia de Cahyawijaya, Lovenia y Fung (2024) sobre la efectividad del *in-context learning* con ejemplos cuidadosamente seleccionados.

La segunda observación es sobre la contribución específica de la recuperación aumentada al rendimiento del modelo de frontera. La configuración C (Claude Opus 4.7 zero-shot) obtiene únicamente 4,37 BLEU en Inga-español y 0,32 BLEU en español-Inga, cifras que confirman que el modelo de frontera, sin información adicional sobre la lengua, no resuelve el problema de traducción para el Inga. La incorporación del RAG multi-índice (configuración D) eleva estas cifras en órdenes de magnitud comparables a los reportados por Wang et al. (2024) y por Chen

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera et al. (2024) para QueEn. La estructuración del conocimiento en tres índices independientes (léxico, gramatical y de ejemplos paralelos) constituye, en este sentido, una arquitectura efectiva para el problema, aunque la evidencia disponible no permite cuantificar la contribución marginal de cada índice por separado.

La tercera observación concierne a la asimetría entre direcciones de traducción. Las configuraciones A, B y C registran caídas sustanciales al pasar de Inga-español a español-Inga: la dirección de generación hacia la lengua de bajos recursos es estructuralmente más difícil porque el decodificador no dispone de datos suficientes para aprender la distribución de salida. El adaptador LoRA entra en modo de repetición patológica en español-Inga; el modelo de frontera sin RAG produce salidas mayoritariamente irrelevantes. La configuración D atenúa esta asimetría: la diferencia entre direcciones se reduce de 8 puntos BLEU (configuración B) a aproximadamente 7 puntos (configuración D), y proporcionalmente la dirección difícil pasa de representar el 22 % del rendimiento de la dirección fácil al 61 %. El RAG, al inyectar ejemplos paralelos del corpus, suministra al modelo de frontera plantillas concretas de generación en la lengua de bajos recursos que mitigan el déficit de datos en el preentrenamiento.

La cuarta observación se refiere a la configuración E (refinamiento de la salida del LoRA por Claude con RAG), que no supera a la configuración D directa. El resultado contraintuitivo sugiere que la *semilla* producida por el adaptador, cuya calidad léxica es modesta, sesga al modelo de frontera hacia traducciones menos fieles que las que produciría sin esa influencia. La inspección manual de varios ejemplos confirma que Claude conserva errores léxicos del *seed* del LoRA y ajusta únicamente el plano sintáctico, lo que penaliza las métricas basadas en *n-grama*.

La comparación intra-Claude reportada en la Tabla 10 refuerza esta lectura. En la configuración D, donde el modelo recibe contexto recuperado pero no un *seed*, Opus 4.7 aventaja a Sonnet 4.6 en aproximadamente 6 puntos BLEU en la dirección Inga-español y 3 puntos en la inversa: la mayor capacidad del modelo se traduce directamente en mejor uso del contexto. En la configuración E, donde el *seed* del LoRA introduce errores léxicos, la ventaja se invierte: Sonnet 4.6 produce un BLEU ligeramente superior (12,01 frente a 10,88 en Inga-español). El patrón sugiere que el modelo más capaz reescribe con mayor agresividad el *seed*

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera defectuoso, alejándose más de la referencia que el modelo menos avanzado, que tiende a preservar el *seed* y a ajustar de forma más conservadora. La implicación práctica es que la estrategia de refinamiento jerárquico no se beneficia automáticamente del escalado del modelo de refinamiento; requiere un *seed* de calidad superior a la disponible con un adaptador entrenado sobre 4.512 pares paralelos.

La comparación con la literatura cercana sostiene los resultados sin forzarlos. El BLEU de 17,89 que alcanza la configuración D en Inga-español queda por encima del rango que García Gilabert et al. (2024) reportan para el quechua en la tarea compartida de AmericasNLP, y se ubica en la franja alta de lo que describe Chen et al. (2024) para el sistema QueEn de quechua-inglés. No es una comparación estricta, porque los conjuntos de prueba difieren, pero sitúa el trabajo en un orden de magnitud razonable para una lengua de esta escala de recursos. La revisión de Salazar, Manrique y Pereira Nunes (2025) sobre lenguas indígenas colombianas refuerza la idea de que las aproximaciones basadas en modelos de frontera con contexto externo están desplazando a las puramente neuronales en este régimen de datos.

Merece discusión el papel del ajuste fino, que el experimento no descarta pero sí redimensiona. La configuración B (NLLB con LoRA) mejora de forma clara sobre el zero-shot en la dirección Inga-español, lo que confirma que el adaptador aprende algo útil del corpus. El problema es la otra dirección: con poco más de cuatro mil pares, el decodificador no aprende a generar Inga, y por eso la configuración B se hunde en español-Inga. La lectura combinada de las configuraciones B, D y E sugiere que el ajuste fino y la recuperación no compiten: cada uno ataca un cuello de botella distinto, y la vía más prometedora a futuro podría ser combinarlos mejor de lo que lo hace la configuración E.

Tres limitaciones del estudio deben señalarse para encuadrar las conclusiones anteriores. La primera es la ausencia del dialecto Medio Putumayo en el corpus de entrenamiento. La cartilla *Antihua Pacay Gentecunapa Parlocuna* es la única fuente disponible para esa variante, y su alineación oracional requiere un alineador semántico basado en *sentence embeddings* multilingües que no forma parte del alcance de este estudio. La segunda es el tamaño acotado del subconjunto del *val set* utilizado para reportar métricas: 100 ejemplos por dirección frente a los 564 disponibles, decisión motivada por el control de costos en las llamadas a la API y por

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera el tiempo de inferencia local del adaptador NLLB. La tercera es la ausencia de validación humana con hablantes nativos, indispensable para capturar dimensiones de calidad que las métricas automáticas no reflejan, como la naturalidad cultural y la fluidez idiomática en cada dialecto (Ebrahimi et al., 2024; Mager et al., 2023).

5.3. LÍNEAS DE TRABAJO FUTURAS

Las limitaciones identificadas no cierran el trabajo sino que abren una agenda concreta. Se describen a continuación, ordenadas más por viabilidad que por ambición.

La incorporación del dialecto Medio Putumayo es la tarea más urgente, porque su ausencia sesga el corpus hacia el Alto Putumayo y limita la utilidad real del sistema para una parte de la comunidad. La cartilla Antihua Pacay quedó fuera del entrenamiento por la baja calidad de su alineación oracional, pero un alineador semántico basado en embeddings multilingües, del tipo LaBSE, permitiría recuperar buena parte de ese material sin depender de la coincidencia canónica versículo a versículo que se usó con el Nuevo Testamento. Es una línea de costo moderado y alto impacto.

En el plano del modelo, un estudio sistemático de ablations sobre el adaptador LoRA permitiría entender qué parte de la mejora viene de la capacidad del adaptador y qué parte del corpus duplicado para entrenamiento bidireccional. Variar el rango del adaptador, el factor de escala y las capas intervenidas, manteniendo fijo el resto del pipeline, daría una imagen más precisa del techo del ajuste fino para este par. La literatura sobre variantes más recientes de ajuste eficiente, como QLoRA (Dettmers et al., 2023) y DoRA (Liu et al., 2024), ofrece puntos de partida concretos.

El escalado del modelo base, de NLLB-200-distilled-600M a la versión de 3.300 millones de parámetros, es viable en la estación de cómputo local pero con tiempos de entrenamiento e inferencia bastante mayores. La pregunta abierta es si ese salto de capacidad cierra por sí solo la brecha en la dirección español-Inga o si, como sugiere el experimento actual, el verdadero cuello de botella sigue siendo la cantidad de datos y no el tamaño del modelo.

La validación con hablantes nativos es la pieza que falta para cerrar el círculo. Un protocolo realista usaría una rúbrica de tres dimensiones (adecuación, fluidez y elección dialectal

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera correcta) sobre una muestra estratificada por dialecto y por dominio, y serviría a la vez para auditar las métricas automáticas y para detectar errores que estas no capturan, como la lengua incorrecta documentada en la subsección 4.6.1. Este trabajo conecta de forma directa con las consideraciones éticas que plantea Mager et al. (2023) sobre dar voz a los hablantes en la traducción de lenguas indígenas.

Por último, el empaquetado del sistema como aplicación local reproducible trasladaría el resultado de la investigación a una herramienta utilizable por la comunidad. Una interfaz de línea de comandos que reciba un texto y una dirección de traducción, apoyada en el retriever y en los prompts ya construidos, es un objetivo de ingeniería más que de investigación, pero es el que convierte el TFM en algo que sobrevive a la entrega.

Referencias bibliográficas

- Asamblea Nacional Constituyente de Colombia. (1991). *Constitución Política de Colombia*, Artículo 10.
http://www.secretariassenado.gov.co/senado/basedoc/constitucion_politica_1991.html
- Attieh, J., Hopton, Z., Scherrer, Y., y Samardžić, T. (2024). System description of the NordicsAlps submission to the AmericasNLP 2024 machine translation shared task. En *Proceedings of the 4th Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP 2024)* (pp. 150-158). Association for Computational Linguistics.
<https://aclanthology.org/2024.americasnlp-1.18/>
- Cahyawijaya, S., Lovenia, H., y Fung, P. (2024). LLMs are few-shot in-context low-resource language learners. En *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL 2024)*.
<https://arxiv.org/abs/2403.16512>
- Chen, J., Shu, P., Li, Y., Zhao, H., Jiang, H., Pan, Y., Zhou, Y., Liu, Z., Howe, L. C., y Liu, T. (2024). *QueEn: A large language model for Quechua-English translation* [arXiv preprint].
<https://arxiv.org/abs/2412.05184>
- Congreso de la República de Colombia. (2010). *Ley 1381 de 2010, por la cual se desarrollan los artículos 7°, 8°, 10 y 70 de la Constitución Política y se dictan normas sobre reconocimiento, fomento, protección, uso, preservación y fortalecimiento de las lenguas de los grupos étnicos de Colombia y sobre sus derechos lingüísticos y los de sus hablantes*. Diario Oficial No. 47.603.
<https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=38741>
- de Gibert, O., Pugh, R., Marashian, A., Vazquez, R., Ebrahimi, A., Denisov, P., Rice, E., Gow-Smith, E., Prieto, J., Robles, M., Manrique, R., Moreno, O., Lino, A., Coto-Solano, R., Alvarez, A., Agüero-Torales, M., Ortega, J. E., Chiruzzo, L., Oncevay, A., Rijhwani, S., von der Wense, K., y Mager, M. (2025). Findings of the AmericasNLP 2025 shared tasks on machine translation, creation of educational material, and translation metrics for indigenous

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera languages of the Americas. En *Proceedings of the Fifth Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)* (pp. 134-152). <https://aclanthology.org/2025.americasnlp-1.16/>

DeGenaro, D., y Lupicki, T. (2024). Experiments in Mamba sequence modeling and NLLB-200 fine-tuning for low resource multilingual machine translation. En *Proceedings of the 4th Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP 2024)* (pp. 188-194). <https://aclanthology.org/2024.americasnlp-1.22/>

Dettmers, T., Pagnoni, A., Holtzman, A., y Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. En *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*. <https://arxiv.org/abs/2305.14314>

Dhawan, A., Driggers-Ellis, C., Grant, C., y Wang, D. Z. (2026). *Improving indigenous language machine translation with synthetic data and language-specific preprocessing* [arXiv preprint]. <https://arxiv.org/abs/2601.03135>

Doran, G. T. (1981). There's a S.M.A.R.T. way to write management's goals and objectives. *Management Review (AMA FORUM)*, 70(11), 35-36.

Ebrahimi, A., de Gibert, O., Vazquez, R., Coto-Solano, R., Denisov, P., Pugh, R., Mager, M., Oncevay, A., Chiruzzo, L., von der Wense, K., y Rijhwani, S. (2024). Findings of the AmericasNLP 2024 shared task on machine translation. En *Proceedings of the 4th Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP 2024)* (pp. 236-246). <https://aclanthology.org/2024.americasnlp-1.28/>

Enis, M., y Hopkins, M. (2024). *From LLM to NMT: Advancing low-resource machine translation with Claude* [arXiv preprint]. <https://arxiv.org/abs/2404.13813>

Finkelstein, M., Caswell, I., Domhan, T., Peter, J.-T., Juraska, J., Riley, P., Deutsch, D., Kovacs, G., Dilanni, C., Cherry, C., Briakou, E., Nielsen, E., Luo, J., Black, K., Mullins, R., Agrawal, S., Xu, W., Kats, E., Jaskiewicz, S., Freitag, M., y Vilar, D. (2026). *TranslateGemma: Technical report* [arXiv preprint]. <https://arxiv.org/abs/2601.09012>

Garcia Gilabert, J., Sant, A., Escolano, C., De Luca Fornaciari, F., Mash, A., y Melero, M. (2024).

BSC submission to the AmericasNLP 2024 shared task. En *Proceedings of the 4th Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP 2024)* (pp. 143-149). <https://aclanthology.org/2024.americasnlp-1.17/>

Hendy, A., Abdelrehim, M., Sharaf, A., Raunak, V., Gabr, M., Matsushita, H., Kim, Y. J., Afify, M., y Awadalla, H. H. (2023). *How good are GPT models at machine translation? A comprehensive evaluation* [arXiv preprint]. <https://arxiv.org/abs/2302.09210>

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., y Chen, W. (2022). LoRA: Low-rank adaptation of large language models. En *International Conference on Learning Representations (ICLR 2022)*. <https://arxiv.org/abs/2106.09685>

Jamioy Yanangona de Peña, O. (1985). *Antihua Pacay Gentecunapa parlocuna: Tradiciones de los Inganos Pacayes* (Cartilla Inga, Serie: Historias Tradicionales, Edición provisional). Proyecto Bilingüe Inga-Castellano del Vicariato Apostólico de Sibundoy; SIL International Language and Culture Archives.

Kudugunta, S., Caswell, I., Zhang, B., Garcia, X., Choquette-Choo, C. A., Lee, K., Xin, D., Kusupati, A., Stella, R., Bapna, A., y Firat, O. (2023). MADLAD-400: A multilingual and document-level large audited dataset. En *Advances in Neural Information Processing Systems 36 (NeurIPS 2023 Datasets and Benchmarks Track)*. <https://arxiv.org/abs/2309.04662>

Levinsohn, S. H., y Mongui, R. (s.f.). *Inga Kichwa: Una gramática pedagógica del Inga (Partes 1 y 2)*. Instituto Lingüístico de Verano.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., y Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. En *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*. <https://arxiv.org/abs/2005.11401>

Liu, S.-Y., Wang, C.-Y., Yin, H., Molchanov, P., Wang, Y.-C. F., Cheng, K.-T., y Chen, M.-H. (2024). DoRA: Weight-decomposed low-rank adaptation. En *Proceedings of the 41st International Conference on Machine Learning (ICML 2024)*. <https://arxiv.org/abs/2402.09353>

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

Mager, M., Mager, E., Kann, K., y Vu, N. T. (2023). Ethical considerations for machine translation of indigenous languages: Giving a voice to the speakers. En *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL 2023)*. <https://aclanthology.org/2023.acl-long.313/>

NLLB Team, Costa-jussà, M. R., Cross, J., Çelebi, O., Elbayad, M., Heafield, K., Heffernan, K., Kalbassi, E., Lam, J., Licht, D., Maillard, J., Sun, A., Wang, S., Wenzek, G., Youngblood, A., Akula, B., Barrault, L., Mejia Gonzalez, G., Hansanti, P., ... Wang, J. (2022). *No language left behind: Scaling human-centered machine translation* [arXiv preprint]. <https://arxiv.org/abs/2207.04672>

NLLB Team, Costa-jussà, M. R., Cross, J., Çelebi, O., Elbayad, M., Heafield, K., Heffernan, K., Kalbassi, E., Lam, J., Licht, D., Maillard, J., Sun, A., Wang, S., Wenzek, G., Youngblood, A., Akula, B., Barrault, L., Mejia Gonzalez, G., Hansanti, P., ... Wang, J. (2024). Scaling neural machine translation to 200 languages. *Nature*, 630(8018), 841-846. <https://doi.org/10.1038/s41586-024-07335-x>

Popović, M. (2017). chrF++: Words helping character n-grams. En *Proceedings of the Second Conference on Machine Translation (WMT 2017)* (pp. 612-618). <https://aclanthology.org/W17-4770/>

Prieto, J., Martinez, C., Robles, M., Moreno, A., Palacios, S., y Manrique, R. (2024). Translation systems for low-resource Colombian indigenous languages: A first step towards cultural preservation. En *Proceedings of the 4th Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP 2024)* (pp. 7-14). <https://aclanthology.org/2024.americasnlp-1.2/>

Rei, R., De Souza, J. G. C., Alves, D., Zerva, C., Farinha, A. C., Glushkova, T., Lavie, A., Coheur, L., y Martins, A. F. T. (2022). COMET-22: Unbabel-IST 2022 submission for the metrics shared task. En *Proceedings of the Seventh Conference on Machine Translation (WMT 2022)* (pp. 578-585). <https://aclanthology.org/2022.wmt-1.52/>

Salazar, I., Manrique, R., y Pereira Nunes, B. (2025). Machine translation strategies for low-resource Colombian indigenous languages. *SN Computer Science*, 6. <https://doi.org/10.1007/s42979-025-04255-z>

- Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera
- Su, T., Peng, X., Thillainathan, S., Guzmán, D., Ranathunga, S., y Lee, E.-S. A. (2024). *Unlocking parameter-efficient fine-tuning for low-resource language translation* [arXiv preprint]. <https://arxiv.org/abs/2404.04212>
- Tandioy Jansasoy, F., Levinsohn, S. H., y Tandioy Chasoy, D. (1997). *Diccionario Inga* (Edición interina en el nuevo alfabeto). Comité de Educación Inga de la Organización Musu Runakuna.
- Tonja, A. L., Balouchzahi, F., Butt, S., Kolesnikova, O., Ceballos, H., Gelbukh, A., y Solorio, T. (2024). NLP progress in indigenous Latin American languages. En *Findings of the Association for Computational Linguistics: NAACL 2024*. <https://arxiv.org/abs/2404.05365>
- UNESCO. (2022). *World Atlas of Languages*. United Nations Educational, Scientific and Cultural Organization. <https://en.wal.unesco.org/>
- Wang, J., Meng, F., Zhang, Y., y Zhou, J. (2024). *Retrieval-augmented machine translation with unstructured knowledge* [arXiv preprint]. <https://arxiv.org/abs/2412.04342>
- Wycliffe Bible Translators. (2012). *Kaipimi Taita Dios Rimaku: El Nuevo Testamento en el idioma Inga de Colombia* (2ª ed.) [Bajo licencia Creative Commons BY-NC-ND 3.0].
- Zhang, S., Frey, B., y Bansal, M. (2022). How can NLP help revitalize endangered languages? A case study and roadmap for the Cherokee language. En *Proceedings of ACL 2022*. <https://aclanthology.org/2022.acl-long.507/>
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., y Artzi, Y. (2020). BERTScore: Evaluating text generation with BERT. En *International Conference on Learning Representations (ICLR 2020)*. <https://arxiv.org/abs/1904.09675>
- Zhu, W., Liu, H., Dong, Q., Xu, J., Huang, S., Kong, L., Chen, J., y Li, L. (2024). Multilingual machine translation with large language models: Empirical results and analysis. En *Findings of the Association for Computational Linguistics: NAACL 2024* (pp. 2765-2781). <https://aclanthology.org/2024.findings-naacl.176/>

Anexo A. Código fuente y datos analizados

El código fuente del TFM se aloja en el repositorio <https://github.com/Purakuna/tfm-inga-traduccion> de la organización Purakuna, de acceso restringido durante la ejecución del proyecto, con el enlace comunicado al director del trabajo. El proyecto se gestiona como paquete Python reproducible con `pyproject.toml` y `uv.lock`, instalable mediante el gestor de dependencias `uv`. La estructura del repositorio se organiza según se describe a continuación.

La carpeta `notebooks/` contiene doce *notebooks* de Jupyter ejecutables en orden numérico:

`00_setup_entorno.ipynb`, configuración y validación del entorno local (Python 3.11, PyTorch con aceleración MPS, librerías centrales) y prueba de inferencia zero-shot del modelo multilingüe utilizado como base.

`01_eda_recursos_base.ipynb`, análisis exploratorio de los cinco recursos lingüísticos primarios y primer volcado del *Diccionario Inga*.

`02_extraccion_corpus_NT.ipynb`, extracción heurística inicial del Nuevo Testamento en Inga y de las narrativas *Antihua Pacay*.

`03_extraccion_NT_inga_estructurada.ipynb`, parser estructurado del NT Inga que recupera 6.083 versículos únicos con tupla canónica (libro, capítulo, versículo).

`04_extraccion_NT_rv1909.ipynb`, parser de los 27 archivos USFM del NT Reina-Valera 1909 con limpieza de marcado anotativo.

`05_alineacion_NT.ipynb`, *inner join* canónico entre las dos versiones del NT con filtros de calidad, resultado: 5.589 pares paralelos.

`06_antihua_pacay_alineado.ipynb`, alineación exploratoria de Antihua Pacay (no incorporada al corpus de entrenamiento por baja calidad de la alineación oracional sin alineador semántico).

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

`07_corpus_particiones.ipynb`, unificación, particiones train/val/test 80/10/10

con semilla 42 y generación de la Figura 8.

`08_indexacion_vectorial.ipynb`, construcción de los cuatro índices LanceDB

con embeddings `gemini-embedding-001`.

`09_finetuning_lora.ipynb`, ajuste fino bidireccional de NLLB-200-distilled-600M

mediante adaptadores LoRA.

`10_medicion_nllb_configs.ipynb`, evaluación de las configuraciones A y B en

ambas direcciones sobre 100 ejemplos del *val set*.

`11_medicion_llm_rag.ipynb`, evaluación de las configuraciones C, D y E con

Claude Sonnet 4.6 y generación de la Figura 11.

La carpeta `src/` contiene los módulos reutilizables del proyecto, organizados en tres subpaquetes:

`src/rag/` con `embeddings.py` (wrapper de Gemini con throttling y reintento), `indexes.py` (gestión de tablas LanceDB) y `retriever.py` (API uniforme multi-índice).

`src/models/` con `nllb_lora.py` (setup de NLLB y aplicación de LoRA) y `claude_rag.py` (pipeline LLM con prompts estructurados por dirección).

`src/eval/` con `metrics.py` (wrappers de BLEU, chrF++ y BERTScore).

La carpeta `datos/` contiene las salidas estructuradas y los corpus generados:

`datos/diccionario_inga.jsonl`, 4.900 entradas léxicas con lema, categoría gramatical y glosa.

`datos/nt_inga_estructurado.jsonl`

y

`datos/nt_rv1909_estructurado.jsonl`, salidas de los notebooks 03 y 04.

`datos/nt_paralelo.jsonl`, 5.589 pares paralelos resultantes de la alineación canónica.

Diseño e implementación de un sistema comparativo de traducción automática Inga-español mediante fine-tuning de modelos multilingües y RAG sobre modelos de lenguaje de frontera

`datos/antihua_pacay_alineado.jsonl`, 86 pares exploratorios del Medio Putumayo.

`datos/corpus_paralelo.jsonl`, corpus unificado.

`datos/splits/train.jsonl`, `val.jsonl`, `test.jsonl`, particiones 80/10/10.

`datos/metricas_entrega2.json`, métricas de las cinco configuraciones con Claude Opus 4.7 (reporte principal del Capítulo 4).

`datos/metricas_entrega2_sonnet.json`, métricas de las configuraciones C, D y E con Claude Sonnet 4.6 sobre el mismo conjunto de validación, utilizadas para la comparación intra-Claude de la Tabla 10.

`datos/predicciones_val_completo.jsonl`, predicciones por configuración para inspección cualitativa.

`datos/ocr/`, fuentes OCR derivadas, con subcarpetas `inga-kichwa/` (cinco fuentes primarias del Inga) y `reina-valera-1909/` (27 archivos USFM del NT en español).

La carpeta `bibliografia/` contiene la base bibliográfica verificada del proyecto (`refs_verificadas.md`), con identificadores estables asociados a cada entrada.

La carpeta `entrega2/` contiene el documento maestro del trabajo y sus recursos gráficos asociados. El `script entrega2/build_docx_e2.py` genera bloques en formato Word a partir del Markdown maestro y la plantilla oficial UNIR, aplicando los estilos requeridos para captions APA y conservando los estilos de la plantilla.

Licenciamiento. El código desarrollado específicamente para el TFM se publica bajo licencia MIT. Los datos derivados de fuentes externas heredan las licencias de sus respectivas fuentes primarias: el *Nuevo Testamento en el idioma Inga de Colombia* se distribuye bajo Creative Commons Atribución-NoComercial-SinObraDerivada 3.0 (Wycliffe Bible Translators, 2012); las narrativas *Antihua Pacay Gentecunapa Parlocuna* (Jamioy Yanangona de Peña, 1985) forman parte de los Archivos de Lengua y Cultura del SIL International, disponibles bajo términos de uso académico y de investigación; el NT Reina-Valera 1909 se distribuye en dominio público a través de eBible.org.